

Inverse Probleme in der Geophysik  
Vorlesung (Vertretung K. Spitzer)  
TU Bergakademie Freiberg, SS 2020

Teil 2: Methode der kleinsten Quadrate und Auflösungsmatrizen

Thomas Günther (LIAG Hannover)  
([Thomas.Guenther@extern.tu-freiberg.de](mailto:Thomas.Guenther@extern.tu-freiberg.de))

27. April 2020

# Was bisher geschah

## Inversion = Rekonstruktion Modell aus Daten

- Übersicht Inversion in der Angewandten Geophysik
- Daten sind (teils zuordenbare) Zahlen mit Fehlern (Vektoren **d**, **e**)
- Modell abstrahiert Untergrund auf wenige Freiheitsgrade (Modell-Vektor **m**)  
(nach Occams Razor: möglichst einfache Beschreibung)
- Lineares Inversionsproblem **Gm = d**
- Korrekt gestelltes Problem: Existenz, Eindeutigkeit, Stetigkeit
- Aufgabentypen: überbestimmt, unterbestimmt  
(meist sowohl über- als auch unterbestimmte Anteile)
- Einfaches Matrix-Beispiel (3 Gleichungen für 2 Unbekannte)  
Lösung = Kompromiss zwischen allen incl. Fehlerbereiche

# Was bisher geschah

## Inversion = Rekonstruktion Modell aus Daten


- Übersicht Inversion in der Angewandten Geophysik
- Daten sind (teils zuordenbare) Zahlen mit Fehlern (Vektoren **d**, **e**)
- Modell abstrahiert Untergrund auf wenige Freiheitsgrade (Modell-Vektor **m**)  
(nach Occams Razor: möglichst einfache Beschreibung)
- Lineares Inversionsproblem  $\mathbf{Gm} = \mathbf{d} = \mathbf{Gm}^{true} + \mathbf{n}$
- Korrekt gestelltes Problem: Existenz, Eindeutigkeit, Stetigkeit
- Aufgabentypen: überbestimmt, unterbestimmt  
(meist sowohl über- als auch unterbestimmte Anteile)
- Einfaches Matrix-Beispiel (3 Gleichungen für 2 Unbekannte)  
Lösung = Kompromiss zwischen allen incl. Fehlerbereiche

# Inhalt der heutigen Veranstaltung


- Zusammenfassung und Fragen
- Troubleshooting Julia und Jupyter Notebooks (live)
- Die Methode der kleinsten Quadrate (pdf)
- Berücksichtigung von Daten-Fehlern
- Fortsetzung minimalistisches Matrix-Problem
- Auflösungsmatrizen: Modellauflösung, Dateninformation
- Übungsbeispiel lineare Regression
- Eigenwertzerlegung, Singulärwertzerlegung

# Über- und Unterbestimmtheit (Menke, 2012)


**Even-determined**




**Over-determined**



**Under-determined**



**Mixed-determined**



# Beispiel überbestimmtes Problem

$$m_1 - m_2 = -1$$


(1)

$$2m_1 - m_2 = 0$$

(2)

$$m_1 + m_2 = 2.5$$

(3)



Es gibt mehr unabhängige Gleichungen als Unbekannte.

# Beispiel überbestimmtes Problem

$$m_1 - m_2 = -1$$


(1)

$$2m_1 - m_2 = 0$$

(2)

$$m_1 + m_2 = 2.5$$

(3)



Es gibt mehr unabhängige Gleichungen als Unbekannte.

# Die Methode der kleinsten Quadrate

Ausgangspunkt ist die Minimierung des Residuums  $\mathbf{d} - \mathbf{Gm}$ , im Sinne der kleinsten Quadrate

$$\Phi = \|\mathbf{d} - \mathbf{Gm}\|_2^2 = (\mathbf{d} - \mathbf{Gm})^T (\mathbf{d} - \mathbf{Gm}) = (\mathbf{Gm} - \mathbf{d})^T (\mathbf{Gm} - \mathbf{d}) \quad (4)$$

Die Funktion  $\Phi$  wird auch Zielfunktion (objective function) genannt.

Bedingung für ein Extremum ist das Verschwinden der Ableitungen nach allen freien Parametern.

$$\frac{\partial \Phi}{\partial m} = \frac{\partial}{\partial m} (\mathbf{Gm} - \mathbf{d})^T (\mathbf{Gm} - \mathbf{d}) + (\mathbf{Gm} - \mathbf{d})^T \frac{\partial}{\partial m} (\mathbf{Gm} - \mathbf{d}) = 0 \quad (5)$$

$$\mathbf{G}^T \mathbf{Gm} - \mathbf{G}^T \mathbf{d} + \mathbf{G}^T \mathbf{Gm} - \mathbf{G}^T \mathbf{d} = 0 \quad (6)$$

$$\mathbf{G}^T \mathbf{Gm} = \mathbf{G}^T \mathbf{d} \quad \Rightarrow \quad \mathbf{m} = \mathbf{G}^\dagger \mathbf{d} \quad \text{mit} \quad \mathbf{G}^\dagger = (\mathbf{G}^T \mathbf{G})^{-1} \mathbf{G}^T \quad (7)$$

$\mathbf{G}^\dagger$  wird auch Pseudo-Inverse (Moore-Penrose-Inverse) von  $\mathbf{G}$  genannt



$$\Phi = (\mathbf{d} - \mathbf{Gm})^T (\mathbf{d} - \mathbf{Gm}) = \sum_i \left[ (d_i - \sum_j G_{ij} m_j) (d_i - \sum_k G_{ik} m_k) \right]$$

$$\Phi = \sum_i \left[ d_i d_i - d_i \sum_k G_{ik} m_k - d_i \sum_j G_{ij} m_j + \sum_j G_{ij} m_j \sum_k G_{ik} m_k \right]$$

$$\Phi = \sum_i d_i d_i - 2 \sum_j m_j \sum_i d_i G_{ij} + \sum_i \sum_j \sum_k m_j G_{ij} G_{ik} m_k$$

$$\Phi = \sum_i d_i d_i - 2 \sum_j m_j \sum_i d_i G_{ij} + \sum_j \sum_k m_j m_k \sum_i G_{ij} G_{ik}$$

$$\partial \Phi = \partial m_q = \sum_i \sum_k (\delta_{iq} m_k + m_j \delta_{ik}) \sum_j G_{ij} G_{ik} - 2 \sum_j \delta_{iq} \sum_i G_{ij} d_i = 0$$

$$0 = 2 \sum_k \sum_i G_{iq} G_{ik} - 2 \sum_i G_{iq} d_i = 2 \mathbf{G}^T \mathbf{G} - 2 \mathbf{G}^T \mathbf{d}$$

## Herleitung (2)

Wir stören unser Modell  $\mathbf{m}$  durch eine Änderung  $t\delta\mathbf{m}$

$$\Phi(t) = (\mathbf{d} - \mathbf{G}(\mathbf{m} + t\delta\mathbf{m}))^T (\mathbf{d} - \mathbf{G}(\mathbf{m} + t\delta\mathbf{m}))$$

$$\Phi(t) = (\mathbf{m} + t\delta\mathbf{m})^T \mathbf{G}^T \mathbf{G} (\mathbf{m} + t\delta\mathbf{m}) - 2(\mathbf{m} + t\delta\mathbf{m})^T \mathbf{G}^T \mathbf{d} + \mathbf{d}^T \mathbf{d}$$

$$\Phi(t) = t^2(\delta\mathbf{m}^T \mathbf{G}^T \mathbf{G} \delta\mathbf{m}) + 2t(\delta\mathbf{m}^T \mathbf{G}^T \mathbf{G} \mathbf{m} - \delta\mathbf{m}^T \mathbf{G}^T \mathbf{d}) + (\mathbf{m}^T \mathbf{G}^T \mathbf{G} \mathbf{m} + \mathbf{d}^T \mathbf{d} - 2\mathbf{m}^T \mathbf{G}^T \mathbf{d})$$

$\Phi(t)$  hat ein Minimum bei  $t = 0$ , also muss  $\partial\Phi/\partial t$  verschwinden:

$$\partial\Phi(t=0)/\partial t = 2(\delta\mathbf{m}^T \mathbf{G}^T \mathbf{G} \mathbf{m} - \delta\mathbf{m}^T \mathbf{G}^T \mathbf{d}) = 2\delta\mathbf{m}^T (\mathbf{G}^T \mathbf{G} \mathbf{m} - \mathbf{G}^T \mathbf{d}) = 0$$

Das das für jedes  $\delta\mathbf{m}$  gilt, muss  $\mathbf{G}^T \mathbf{G} \mathbf{m} = \mathbf{G}^T \mathbf{d}$  sein

# Die Methode der kleinsten Quadrate

Daraus folgen die Normalgleichungen

$$\mathbf{G}^T(\mathbf{d} - \mathbf{G}\mathbf{m}) = 0 = \mathbf{G}^T\mathbf{G}\mathbf{m} - \mathbf{G}^T\mathbf{d}$$

mit der (nun eindeutigen) Least Squares Lösung

$$\mathbf{m} = (\mathbf{G}^T\mathbf{G})^{-1}\mathbf{G}^T\mathbf{d} = \mathbf{G}^\dagger\mathbf{d} \quad \text{mit} \quad \mathbf{G}^\dagger = (\mathbf{G}^T\mathbf{G})^{-1}\mathbf{G}^T$$

Maß für die Anpassung ist die (normalisierte) Residuumsnorm

$$\|\mathbf{d} - \mathbf{f}(\mathbf{m})\| = \sqrt{1/N \sum (d_i - f_i(\mathbf{m}))^2}$$

auch bezeichnet als RMS (root mean square)

# Gewichtete Minimierung

## Was passiert bei verschiedener Genauigkeit der Daten?

Wichtung des Datenmisfits durch individuellen Datenfehler  $\varepsilon_i$ :

$$\sum \left( \frac{d_i - f_i(\mathbf{m})}{\varepsilon_i} \right)^2 \rightarrow \min$$

(Ersetzung  $d_i$  durch  $\hat{d}_i = d_i/\varepsilon_i$ ) führt zu

$$\mathbf{m} = (\hat{\mathbf{G}}^T \hat{\mathbf{G}})^{-1} \hat{\mathbf{G}}^T \hat{\mathbf{d}}$$

mit  $\hat{\mathbf{G}} = \text{diag}(1/\varepsilon_i) \cdot \mathbf{G}$

zugehöriges Fehlermaß: fehlergewichteter Misfit (idealerweise im Mittel 1)

$$\chi^2 = \frac{1}{N} \sum \left( \frac{d_i - f_i(\mathbf{m})}{\varepsilon_i} \right)^2$$

# Rauschen und Fehler

- Fehler (immer da) werden mit invertiert
- Least-Squares-Inversion = Gauss-Verteilung des Residuums
- Modellvariation durch Wiederholung: Fehleranalyse
- je größer Daten-Fehler desto größer Modell-Variation
- auch abhängig von Gutartigkeit des Problems
- ungleiches Rauschen  $\Rightarrow$  systematische Verzerrung
- Wichtung der Daten mit reziprokem Fehler  
 $\Rightarrow$  gewichtete Normalgleichungen

$$\mathbf{m} = (\hat{\mathbf{G}}^T \hat{\mathbf{G}})^{-1} \hat{\mathbf{G}}^T \hat{\mathbf{d}} \text{ mit } \hat{\mathbf{G}} = \text{diag}(1/\varepsilon_i) \cdot \mathbf{G}$$

- Maß für Anpassung:  $\chi^2$  (fehlergewichtetes Quadratmittel)

# Auflösungsmatrizen

## Modell-Auflösung

$$\mathbf{d} = \mathbf{G}\mathbf{m}^{\text{true}} + \mathbf{n}$$

Matrix-Inversion mit inversem Operator  $\mathbf{G}^\dagger$ :

$$\mathbf{m}^{\text{est}} = \mathbf{G}^\dagger \mathbf{d} = \mathbf{G}^\dagger \mathbf{G} \mathbf{m}^{\text{true}} + \mathbf{G}^\dagger \mathbf{n} = \mathbf{R}^M \mathbf{m}^{\text{true}} + \mathbf{G}^\dagger \mathbf{n}$$

mit der Modell-Auflösungsmatrix  $\mathbf{R}^M = \mathbf{G}^\dagger \mathbf{G}$

⇒ Wie spiegelt sich die Wahrheit ( $\mathbf{m}^{\text{true}}$ ) im Ergebnis ( $\mathbf{m}^{\text{est}}$ ) wider?

Diagonale von  $\mathbf{R}^M$ : Auflösung der Modellparameter, Nebendiagonale: Verzerrung

## Überbestimmte Probleme

$$\mathbf{G}^\dagger = (\mathbf{G}^T \mathbf{G})^{-1} \mathbf{G}^T \Rightarrow \mathbf{R}^M = (\mathbf{G}^T \mathbf{G})^{-1} \mathbf{G}^T \mathbf{G} = \mathbf{I} \Rightarrow \text{perfekte Modellauflösung}$$

# Auflösungsmatrizen

## Daten-Informationsdichtematrix

$$\mathbf{m}^{\text{est}} = \mathbf{G}^\dagger \mathbf{d}^{\text{obs}}$$

Wie werden die Daten durch das Modell erklärt?

$$\mathbf{d}^{\text{est}} = \mathbf{G} \mathbf{m}^{\text{est}} = \mathbf{G} \mathbf{G}^\dagger \mathbf{d}^{\text{obs}} = \mathbf{R}^D \mathbf{d}^{\text{obs}}$$

mit der Daten-Auflösungsmatrix (Informationsdichtematrix):


$$\mathbf{R}^D = \mathbf{G} \mathbf{G}^\dagger$$

Diagonale von  $\mathbf{R}^D$ : Informationsgehalt der Daten, Nebendiagonale: Korrelation

## Überbestimmte Probleme

$$\mathbf{G}^\dagger = (\mathbf{G}^T \mathbf{G})^{-1} \mathbf{G}^T \quad \Rightarrow \quad \mathbf{R}^D = \mathbf{G} (\mathbf{G}^T \mathbf{G})^{-1} \mathbf{G}^T$$

# Lineare Regression(1)





## Lineare Regression(2)

Die Daten:  $y_i$  Das Modell:  $a, b$  Der Vorwärtsoperator: Abbildung von  $(a, b)$  auf  $a + bx$  durch Matrix-Vektor-Produkt.

- 1 Wie muss diese aussehen? (Überlegung 1, danach 2 Werte)
- 2 Stellen Sie  $\mathbf{G}$  auf und lösen Sie die Normalengleichungen

$$\mathbf{G}^T(\mathbf{d} - \mathbf{G}\mathbf{m}) = 0 \text{ bzw. } \mathbf{G}^T\mathbf{G}\mathbf{m} = \mathbf{G}^T\mathbf{d}$$

- 3 Testen Sie mit idealen Daten (graphischer Vergleich)!
- 4 Verrauschen Sie die Daten und variieren Sie die Fehler.
- 5 Berechnen Sie die Fehlerquadratsumme!
- 6 Wiederholen Sie (neue Verrauschung) & plotten Sie die alle Ergebnisse zusammen! Wie verteilen sie sich?
- 7 Erhöhen Sie den Polynomgrad schrittweise!

# Eigenwertzerlegung

Die Matrix **A** projiziert einen Vektor in eine andere Richtung. Besondere Vektoren sind Eigenvektoren, die ihre Richtung beibehalten:

$$\mathbf{Ax} = \lambda \mathbf{x}$$

Die Lösung der Gleichung

$$(\mathbf{A} - \lambda \mathbf{I})\mathbf{x} = 0$$

führt zur Bestimmung der Eigenwerte über das charakteristische Polynom  $\det(\mathbf{A} - \lambda \mathbf{I}) = 0$

Verschiedene Eigenwerte korrespondieren mit linear unabhängigen Eigenvektoren. Für symmetrische Matrizen existiert eine Faktorisierung mit den EV in  $\mathbf{Q}$  und den EW in  $\mathbf{\Lambda} = \text{diag} \lambda_i$

$$\mathbf{A} = \mathbf{Q} \mathbf{\Lambda} \mathbf{Q}^T$$

# Singulärwertzerlegung

Wir machen aus unserer rechteckigen Matrix  $\mathbf{G}$  eine symmetrische Matrix

$$\mathbf{A} = \begin{bmatrix} 0 & \mathbf{G} \\ \mathbf{G}^T & 0 \end{bmatrix}$$

Diese besitzt eine Eigenwertzerlegung der Form

$$\mathbf{A}\mathbf{x}_i = \lambda_i\mathbf{x}_i \quad \text{mit} \quad \mathbf{x}_i = \begin{bmatrix} \mathbf{u}_i \\ \mathbf{v}_i \end{bmatrix}$$

Damit erhalten wir zwei gekoppelte Eigenwertprobleme für  $\mathbf{G}$  und  $\mathbf{G}^T$ :

$$\mathbf{G}^T\mathbf{u} = \lambda\mathbf{v} \quad \text{und} \quad \mathbf{G}\mathbf{v} = \lambda\mathbf{u} \quad \text{bzw.}$$

$$\mathbf{G}^T\mathbf{G}\mathbf{v} = \lambda^2\mathbf{v} \quad \text{und} \quad \mathbf{G}\mathbf{G}^T\mathbf{u} = \lambda^2\mathbf{u}$$

# Singulärwertzerlegung

Wir erhalten zwei Eigenwertprobleme für die quadratischen Matrizen

$$\mathbf{G}^T \mathbf{G} \mathbf{v} = \lambda^2 \mathbf{v}$$

Mit den Modell-Eigenvektoren  $\mathbf{v}$  und den Daten-Eigenvektoren  $\mathbf{u}$ :

$$\mathbf{G}^T \mathbf{G} \mathbf{v} = \lambda^2 \mathbf{v} \quad \text{und} \quad \mathbf{G} \mathbf{G}^T \mathbf{u} = \lambda^2 \mathbf{u}$$

Die Matrix  $\mathbf{G}$  wird aufgespannt durch alle Eigenvektoren:

$$\mathbf{G} = \mathbf{U} \mathbf{S} \mathbf{V} \quad \text{mit} \quad \mathbf{S} = \text{diag}(\lambda_i)$$

$\mathbf{U} \in R^{N \times N}$  enthält die Daten-Eigenvektoren,  $\mathbf{V} \in R^{N \times N}$  die Modell-Eigenvektoren  
Beide Matrizen sind orthonormal mit  $\mathbf{U}^{-1} = \mathbf{U}^T$  und  $\mathbf{V}^{-1} = \mathbf{V}^T$ . Zu Null ( $\lambda_i = 0$ ) gehörende Vektoren spannen den Modell/Daten-Nullraum auf.

# Die verallgemeinerte Inverse

Der Rang der nichtverschwindenden Singulärwerte sei  $r$ .

Durch ausschließliche Betrachtung des Daten- und Modellvektorraums, also der  $r$  nichtverschwindenden Singulärwerte, erhalten wir einen für unser Problem äquivalenten Operator:

$$\mathbf{G}_r = \mathbf{U}_r \mathbf{\Lambda}_r \mathbf{V}_r^T$$

Da  $\mathbf{U}$  und  $\mathbf{V}$  orthogonal sind, existiert eine verallgemeinerte Inverse

$$\mathbf{G}^\dagger = \mathbf{V}_r \mathbf{\Lambda}_r^{-1} \mathbf{U}_r^T$$

Diese existiert und ist im überbestimmten Fall ( $r \geq N \geq M$ ) identisch mit der Lösung der Normalengleichung.

Für schlecht gestellte Probleme werden Singulärwerte nicht exakt Null, sondern sehr klein. Dann kann der Rang künstlich verkleinert werden (Pseudorang).

# Auflösungsmatrizen und SVD

Durch Einsetzen der verallgemeinerten Inversen ergibt sich

$$\mathbf{m}^{est} = \mathbf{G}^\dagger \mathbf{G} = \mathbf{V}_r \Lambda_r^{-1} \mathbf{U}_r^T \mathbf{U}_r \Lambda_r \mathbf{V}_r \mathbf{m}^{true} = \mathbf{V}_r^T \mathbf{V}_r \mathbf{m}^{true}$$

sowie für die Informationsdichtematrix

$$\mathbf{d}^{est} = \mathbf{G} \mathbf{G}^\dagger = \mathbf{U}_r \Lambda_r \mathbf{V}_r^T \mathbf{V}_r \Lambda_r^{-1} \mathbf{U}_r^T \mathbf{d} = \mathbf{U}_r^T \mathbf{U}_r \mathbf{d}$$

## Lineare Regression(2)

Die Daten:  $y_i$  Das Modell:  $a, b$  Der Vorwärtsoperator: Abbildung von  $(a, b)$  auf  $a + bx$  durch Matrix-Vektor-Produkt.

- 1 Wie muss diese aussehen? (Überlegung 1, danach 2 Werte)
- 2 Stellen Sie  $\mathbf{G}$  auf und lösen Sie die Normalengleichungen

$$\mathbf{G}^T(\mathbf{d} - \mathbf{G}\mathbf{m}) = 0 \text{ bzw. } \mathbf{G}^T\mathbf{G}\mathbf{m} = \mathbf{G}^T\mathbf{d}$$

- 3 Testen Sie mit idealen Daten (graphischer Vergleich)!
- 4 Verrauschen Sie die Daten und variieren Sie die Fehler.
- 5 Berechnen Sie die Fehlerquadratsumme!
- 6 Wiederholen Sie (neue Verrauschung) & plotten Sie die alle Ergebnisse zusammen! Wie verteilen sie sich?
- 7 Erhöhen Sie den Polynomgrad schrittweise!

# Daten-Auflösung Überbestimmte Probleme

Berechnen Sie für die beiden Beispiel-Probleme (3 Geraden, Lineare Regression) die Datenauf Lösungsmatrix und stellen Sie diese dar



# Problem mit Unterbestimmung

2 Messungen (z.B. Strahlen), 3 Parameter (Zellen)

$$\mathbf{Gm} = \begin{bmatrix} 1 & 1 & 0 \\ 0 & 0 & 1 \\ 0 & 0 & 1 \end{bmatrix} \cdot \begin{bmatrix} m_1 \\ m_2 \\ m_3 \end{bmatrix} = \begin{bmatrix} d_1 \\ d_2 \\ d_3 \end{bmatrix} = \mathbf{d}$$

Zerlegung in zwei Unterprobleme:

- Parameter 3 ist überbestimmt
- Parameter 1+2 unterbestimmt

Alle Lösungen mit  $m_1 = d_1 - m_2$  sind gleichrichtig

Für eindeutige (reguläre) Lösungen müssen zusätzliche Bedingungen gestellt werden  $\Rightarrow$

Regularisierung

# Problem mit Unterbestimmung

2 Messungen (z.B. Strahlen), 3 Parameter (Zellen)

$$\mathbf{Gm} = \begin{bmatrix} 1 & 1 & 0 \\ 0 & 0 & 1 \\ 0 & 0 & 2 \end{bmatrix} \cdot \begin{bmatrix} m_1 \\ m_2 \\ m_3 \end{bmatrix} = \begin{bmatrix} d_1 \\ d_2 \\ d_3 \end{bmatrix} = \mathbf{d}$$

Zerlegung in zwei Unterprobleme:

- Parameter 3 ist überbestimmt
- Parameter 1+2 unterbestimmt

Alle Lösungen mit  $m_1 = d_1 - m_2$  sind gleichrichtig

Für eindeutige (reguläre) Lösungen müssen zusätzliche Bedingungen gestellt werden  $\Rightarrow$

Regularisierung

# Problem mit Unterbestimmung

2 Messungen (z.B. Strahlen), 3 Parameter (Zellen)

$$\mathbf{Gm} = \begin{bmatrix} 1 & 1 & 0 \\ 0 & 0 & 1 \\ 1 & 1 & 2 \end{bmatrix} \cdot \begin{bmatrix} m_1 \\ m_2 \\ m_3 \end{bmatrix} = \begin{bmatrix} d_1 \\ d_2 \\ d_3 \end{bmatrix} = \mathbf{d}$$

Zerlegung in zwei Unterprobleme:

- Parameter 3 ist überbestimmt
- Parameter 1+2 unterbestimmt

Alle Lösungen mit  $m_1 = d_1 - m_2$  sind gleichrichtig

Für eindeutige (reguläre) Lösungen müssen zusätzliche Bedingungen gestellt werden  $\Rightarrow$

Regularisierung

# Regularisierung

Wie können wir die Inversion regulär machen?

Zusätzliche Gleichungen im Modellraum

- A-priori-Wissen über eine Unbekannte (Modellreduktion)
- Beziehung zwischen mehreren Unbekannten (z.B. Summe zweier Mächtigkeiten, Differenz/Glattheit)
- ungefähre Schätzung (Referenzmodell)

Zusammen mit Daten im Sinne kleinster Quadrate zu lösen:

$$\begin{bmatrix} 1 & 1 & 0 \\ 0 & 0 & 1 \\ 1 & 0 & 0 \end{bmatrix}$$

Aber: Erste zwei Gleichungen leben im Datenraum, letzte im Modellraum (Einheiten, Rauschen etc.)

# Regularisierung

Wie können wir die Inversion regulär machen?

Zusätzliche Gleichungen im Modellraum

- A-priori-Wissen über eine Unbekannte (Modellreduktion)
- Beziehung zwischen mehreren Unbekannten (z.B. Summe zweier Mächtigkeiten, Differenz/Glattheit)
- ungefähre Schätzung (Referenzmodell)

Zusammen mit Daten im Sinne kleinster Quadrate zu lösen:

$$\begin{bmatrix} 1 & 1 & 0 \\ 0 & 0 & 1 \\ 1 & 1 & 0 \end{bmatrix}$$

Aber: Erste zwei Gleichungen leben im Datenraum, letzte im Modellraum (Einheiten, Rauschen etc.)

# Regularisierung

Wie können wir die Inversion regulär machen?

Zusätzliche Gleichungen im Modellraum

- A-priori-Wissen über eine Unbekannte (Modellreduktion)
- Beziehung zwischen mehreren Unbekannten (z.B. Summe zweier Mächtigkeiten, Differenz/Glattheit)
- ungefähre Schätzung (Referenzmodell)

Zusammen mit Daten im Sinne kleinster Quadrate zu lösen:

$$\begin{bmatrix} 1 & 1 & 0 \\ 0 & 0 & 1 \\ 1 & -1 & 0 \end{bmatrix}$$

Aber: Erste zwei Gleichungen leben im Datenraum, letzte im Modellraum (Einheiten, Rauschen etc.)

## Regularisierung (2)

Minimierung einer gewichteten Summe (Residuum + Constraints):

$$\|\mathbf{G}\mathbf{m} - \mathbf{d}\|^2 + \lambda^2 \|\mathbf{W}\mathbf{m}\|^2 \rightarrow \min$$

( $\lambda$ -Wichtungsfaktor mit Einheit [ $\lambda$ ]=[Daten]/[Modell])

führt zu

$$(\mathbf{G}^T \mathbf{G} + \lambda^2 \mathbf{W}^T \mathbf{W}) \mathbf{m} = \mathbf{G}^T \mathbf{d}$$

- Einfachster Fall:  $\mathbf{W}$  ist Einheitsmatrix  $\mathbf{I}$ :  
gedämpfte Normalengleichungen  $\Rightarrow$  kleinstes Modell
- Weiterer häufiger Fall:  $\mathbf{W}$  ist diskrete Ableitungsmatrix:  
smoothness constraints  $\Rightarrow$  glattestes Modell:

# Occams Prinzip

William v. Occam, Schottland 14. Jh.:

*Pluralitas non est ponenda sine neccesitate!*

*Eine Mehrheit darf nie ohne Not zugrunde gelegt werden.*


*(Wähle aus allen möglichen Lösungen die einfachste)*

Doch wie können wir einfach mathematisch definieren?

- wenige Modellzellen (z.B. Schichten)
- große Glattheit
- möglichst geringe Kontraste
- möglichst wenige Kontraste
- Schätzung von Wahrscheinlichkeiten (Bayes)
- Maximum der Entropie/Informationsgehalt



# Wahl des Regularisierungsparameters



Kompromiss zwischen Datenanpassung und Modellnorm