

Inverse Probleme in der Geophysik  
Vorlesung (Vertretung K. Spitzer)  
TU Bergakademie Freiberg, SS 2020

Teil 5: Regularisierung

Thomas Günther (LIAG Hannover)  
([Thomas.Guenther@extern.tu-freiberg.de](mailto:Thomas.Guenther@extern.tu-freiberg.de))

18. Mai 2020

# Was bisher geschah

## Überbestimmte Probleme

- Methode der kleinsten Quadrate
- Beispiele: Matrixproblem, Lineare Regression
- perfekte Modellauflösung, korrelierte Datenauflösung

## Unterbestimmte Probleme

- Keine eindeutige Lösung: zusätzliche Forderung
- Minimum-Norm-Lösung
- Auflösungsmatrizen noch anschauen

## Singulärwertzerlegung

- klärt Problemtyp über Bestimmung des Rangs  $\Rightarrow$  Test-Aufgabe
- verallgemeinerte Inverse für alle Probleme, LS und MN-Lösung Spezialfälle

# Inhalt der heutigen Veranstaltung

- Zusammenfassung
- Singulärwertzerlegung und Nullräume
- Auflösungsmatrizen unterbestimmte Probleme (JNB live)
- Rückschau Aufgabe Problemtypen (Strahlentomographie)
- Regularisierung
  - ▶ Einführung und Occams Prinzip (pdf)
  - ▶ gedämpfte Inverse, Glattheits-Nebenbedingungen (pdf)
  - ▶ Übung an realistischer Strahlentomographie (JNB)

# Singulärwertzerlegung

Holzhammer der Inversion und Analyse der Anatomie

$$\mathbf{G} = \mathbf{U}\mathbf{S}\mathbf{V}^T \quad \text{mit} \quad \mathbf{S} = \text{diag}(\lambda_i), \mathbf{U}^T\mathbf{U} = \mathbf{V}^T\mathbf{V} = \mathbf{I}$$

Datenraum+Nullraum  $\mathbf{U} = (\mathbf{U}_r, \mathbf{U}_0)$ , Modellraum+Nullraum  $\mathbf{V} = (\mathbf{V}_r, \mathbf{V}_0)$ , Reduktion

$$\mathbf{G}_r = \mathbf{U}_r\mathbf{S}_r\mathbf{V}_r^T$$

Verallgemeinerte Inverse:

$$\mathbf{G}^\dagger = \mathbf{V}_r\mathbf{S}_r^{-1}\mathbf{U}_r^T$$

Modellauflösungsmatrix und Informationsdichtematrix

$$\mathbf{R}^M = \mathbf{V}_r\mathbf{V}_r^T \quad \text{und} \quad \mathbf{R}^D = \mathbf{U}_r\mathbf{U}_r^T$$

# Fälle inverser Probleme

## Gleichbestimmt $M = N = r$

Es existieren weder Modell- noch Daten-Nullraum:  $M = N = r \Rightarrow$  reguläre Inverse, exakte Datenanpassung und Auflösung:  $\mathbf{R}^M = \mathbf{R}^D = \mathbf{I}$ ,

## Überbestimmt: $r = M < N$

Es existiert ein Datennulraum: Jedes  $\mathbf{d}_0$ , das aus  $\mathbf{U}_0$  aufgespannt wird

$$\mathbf{m}^0 = \mathbf{G}^\dagger \mathbf{d}^0 = \mathbf{V}_r \mathbf{S}_r^{-1} \mathbf{U}_r^T \mathbf{d}^0 = 0$$

keine exakte Datenanpassung, Least-Squares Lösung mit  $\mathbf{R}^D \neq \mathbf{I}$ ,  $\mathbf{R}^M = \mathbf{I}$

$$\mathbf{m}_{LS} = (\mathbf{G}^T \mathbf{G}) \mathbf{G}^T \mathbf{d} = (\mathbf{V}_r \mathbf{S}_r^2 \mathbf{V}_r^T)^{-1} (\mathbf{U}_r \mathbf{S}_r \mathbf{V}_r)^T \mathbf{d} = \mathbf{V}_r \mathbf{S}^{-1} \mathbf{U}_r^T \mathbf{d} = \mathbf{G}^\dagger \mathbf{d}$$

# Fälle inverser Probleme

Unterbestimmt:  $r = N < M$

Es existiert ein Modell-Nullraum: Jedes  $\mathbf{m}_0$  das aus  $\mathbf{V}_0$  aufgespannt wird

$$\mathbf{d}^0 = \mathbf{G}\mathbf{m}^0 = \mathbf{U}_r \mathbf{S}_r \mathbf{V}_r^T \mathbf{m}^0 = 0$$

keine eindeutige Lösung,  $\mathbf{R}^M \neq \mathbf{I}$ ,  $\mathbf{R}^D = \mathbf{I}$ , Minimum-Norm-Lösung

$$\mathbf{m}_{MN} = \mathbf{G}^T (\mathbf{G}\mathbf{G}^T)^{-1} \mathbf{d} = \mathbf{V}_r \mathbf{S}_r \mathbf{U}_r^T \mathbf{U}_r \mathbf{S}_r^{-2} \mathbf{U}_r^T \mathbf{d} = \mathbf{V}_r \mathbf{S}^{-1} \mathbf{U}_r^T \mathbf{d} = \mathbf{G}^\dagger \mathbf{d}$$

Gleichzeitig über- und unterbestimmt:  $r < M$ ,  $r < N$

Es existieren sowohl Modell- als auch Daten-Nullräume,  $\mathbf{R}^D \neq \mathbf{I}$  und  $\mathbf{R}^M \neq \mathbf{I}$   
weder Least-Squares noch Minimum-Norm anwendbar, weil  $\mathbf{G}^T \mathbf{G}$  und  $\mathbf{G}\mathbf{G}^T$  singulär

Über-/Unter-Bestimmtheit beschreibt unabhängige Informationen ( $r$ ) verglichen mit  $M$  und  $N$ !

# Auswertung Problemtypen Strahlentomographie

## Was haben wir aus den Problemtypen gelernt?

- formell oft gleich oder überbestimmt ( $M \geq N$ ), aber
- Daten oft redundant  
trotz  $N > M$  Unterbestimmtheit eines Teils des Modells
- Rang der Matrix ausschlaggebend für Problemtyp
- LS-Lösung oder MN-Lösung nur selten anwendbar oder unsinnig
- SVD-Inverse ( $\text{pinv}(G)$ ) immer anwendbar (Holzhammer)
- unbestimmte Parameter 0, unterbestimmte Parameter gemittelt
- Lösungen oft weit weg von synthetischem Modell
-

# Problem kleiner Singulärwerte

## Inversion mit verallgemeinerter Inversen (auch LS, MN!)

$$\mathbf{m} = \mathbf{G}^\dagger \mathbf{d} = \mathbf{V} \mathbf{S}^{-1} \mathbf{U}^T \mathbf{d} = \sum \frac{\mathbf{U}_i^T \mathbf{d}}{s_i} \mathbf{V}_i$$

kleine Singulärwerte führen zu großen Faktoren und haben starken Einfluss auf die Lösung  
Rauschen kann sich verstärken und die Lösung instabil machen

$$\mathbf{G} = \begin{bmatrix} 1 & 1 & 0 & 0 \\ 1 & 1.1 & 0 & 0 \\ 0 & 0 & 1 & 0.5 \\ 0 & 0 & 0.5 & 1 \end{bmatrix} \Rightarrow \mathbf{s} = \begin{bmatrix} 2.05 \\ 1.5 \\ 1.0 \\ 0.05 \end{bmatrix}$$

Lösung: Abgeschnittene SVD-Inverse mit `pinv(G, rtol=0.05)`  $\Rightarrow$  Jupyter Notebook



# Problem mit Unterbestimmung

3 Messungen (z.B. Strahlen), 3 Parameter (Zellen)

$$\mathbf{Gm} = \begin{bmatrix} 1 & 1 & 0 \\ 0 & 0 & 1 \\ 0 & 0 & 1 \end{bmatrix} \cdot \begin{bmatrix} m_1 \\ m_2 \\ m_3 \end{bmatrix} = \begin{bmatrix} d_1 \\ d_2 \\ d_3 \end{bmatrix} = \mathbf{d}$$

Zerlegung in zwei Unterprobleme:

- Parameter 3 ist überbestimmt
- Parameter 1+2 unterbestimmt

Alle Lösungen mit  $m_1 = d_1 - m_2$  sind gleichrichtig

Für eindeutige (reguläre) Lösungen müssen zusätzliche Bedingungen gestellt werden  $\Rightarrow$

Regularisierung

# Problem mit Unterbestimmung

3 Messungen (z.B. Strahlen), 3 Parameter (Zellen)

$$\mathbf{Gm} = \begin{bmatrix} 1 & 1 & 0 \\ 0 & 0 & 1 \\ 0 & 0 & 2 \end{bmatrix} \cdot \begin{bmatrix} m_1 \\ m_2 \\ m_3 \end{bmatrix} = \begin{bmatrix} d_1 \\ d_2 \\ d_3 \end{bmatrix} = \mathbf{d}$$

Zerlegung in zwei Unterprobleme:

- Parameter 3 ist überbestimmt
- Parameter 1+2 unterbestimmt

Alle Lösungen mit  $m_1 = d_1 - m_2$  sind gleichrichtig

Für eindeutige (reguläre) Lösungen müssen zusätzliche Bedingungen gestellt werden  $\Rightarrow$

Regularisierung

# Problem mit Unterbestimmung

3 Messungen (z.B. Strahlen), 3 Parameter (Zellen)

$$\mathbf{Gm} = \begin{bmatrix} 1 & 1 & 0 \\ 0 & 0 & 1 \\ 1 & 1 & 2 \end{bmatrix} \cdot \begin{bmatrix} m_1 \\ m_2 \\ m_3 \end{bmatrix} = \begin{bmatrix} d_1 \\ d_2 \\ d_3 \end{bmatrix} = \mathbf{d}$$

Zerlegung in zwei Unterprobleme:

- Parameter 3 ist überbestimmt
- Parameter 1+2 unterbestimmt

Alle Lösungen mit  $m_1 = d_1 - m_2$  sind gleichrichtig

Für eindeutige (reguläre) Lösungen müssen zusätzliche Bedingungen gestellt werden  $\Rightarrow$

Regularisierung

# Occams Prinzip

William v. Occam, Schottland 14. Jh.:

*Pluralitas non est ponenda sine neccesitate!*

*Eine Mehrheit darf nie ohne Not zugrunde gelegt werden.*

*(Wähle aus allen möglichen Lösungen die einfachste)*

Doch wie können wir einfach mathematisch definieren?

- wenige Modellzellen (z.B. Schichten)
- große Glattheit
- möglichst geringe Kontraste
- möglichst wenige Kontraste
- Höchste Wahrscheinlichkeit (Bayes)
- Maximum der Entropie/Informationsgehalt

# Regularisierung

Wie können wir die Inversion regulär machen?

Zusätzliche Gleichungen im Modellraum

- A-priori-Wissen über eine Unbekannte (Modellreduktion)  
ungefähre Schätzung (Referenzmodell)  $m_1 = d_3$
- Beziehung zwischen Unbekannten (z.B. Summe zweier Mächtigkeiten)  $m_1 + m_2 = d_3$
- Differenz/Glattheit soll klein sein  $m_1 - m_2 = d_3$

Zusammen mit Daten im Sinne kleinster Quadrate zu lösen:

$$\begin{bmatrix} 1 & 1 & 0 \\ 0 & 0 & 1 \\ 1 & 0 & 0 \end{bmatrix}$$

Aber: Erste 2 Gleichungen leben im Datenraum, letzte im Modellraum (Einheiten, Rauschen etc.)

# Regularisierung

Wie können wir die Inversion regulär machen?

Zusätzliche Gleichungen im Modellraum

- A-priori-Wissen über eine Unbekannte (Modellreduktion)  
ungefähre Schätzung (Referenzmodell)  $m_1 = d_3$
- Beziehung zwischen Unbekannten (z.B. Summe zweier Mächtigkeiten)  $m_1 + m_2 = d_3$
- Differenz/Glattheit soll klein sein  $m_1 - m_2 = d_3$

Zusammen mit Daten im Sinne kleinster Quadrate zu lösen:

$$\begin{bmatrix} 1 & 1 & 0 \\ 0 & 0 & 1 \\ 1 & 1 & 0 \end{bmatrix}$$

Aber: Erste 2 Gleichungen leben im Datenraum, letzte im Modellraum (Einheiten, Rauschen etc.)

# Regularisierung

Wie können wir die Inversion regulär machen?

Zusätzliche Gleichungen im Modellraum

- A-priori-Wissen über eine Unbekannte (Modellreduktion)  
ungefähre Schätzung (Referenzmodell)  $m_1 = d_3$
- Beziehung zwischen Unbekannten (z.B. Summe zweier Mächtigkeiten)  $m_1 + m_2 = d_3$
- Differenz/Glattheit soll klein sein  $m_1 - m_2 = d_3$

Zusammen mit Daten im Sinne kleinster Quadrate zu lösen:

$$\begin{bmatrix} 1 & 1 & 0 \\ 0 & 0 & 1 \\ 1 & -1 & 0 \end{bmatrix}$$

Aber: Erste 2 Gleichungen leben im Datenraum, letzte im Modellraum (Einheiten, Rauschen etc.)

# Regularisierung

Wie können wir die Inversion regulär machen?

Zusätzliche Gleichungen im Modellraum

- A-priori-Wissen über eine Unbekannte (Modellreduktion)
- Beziehung zwischen mehreren Unbekannten (z.B. Summe zweier Mächtigkeiten, Differenz/Glattheit)
- ungefähre Schätzung (Referenzmodell)

Zusammen mit Daten im Sinne kleinster Quadrate zu lösen:

$$\begin{bmatrix} 1 & 1 & 0 \\ 0 & 0 & 1 \\ 1 & 0 & 0 \end{bmatrix}$$

Aber: Erste 2 Gleichungen leben im Datenraum, letzte im Modellraum (Einheiten, Rauschen etc.)



# Regularisierung

Wie können wir die Inversion regulär machen?

Zusätzliche Gleichungen im Modellraum

- A-priori-Wissen über eine Unbekannte (Modellreduktion)
- Beziehung zwischen mehreren Unbekannten (z.B. Summe zweier Mächtigkeiten, Differenz/Glattheit)
- ungefähre Schätzung (Referenzmodell)

Zusammen mit Daten im Sinne kleinster Quadrate zu lösen:

$$\begin{bmatrix} 1 & 1 & 0 \\ 0 & 0 & 1 \\ 1 & 1 & 0 \end{bmatrix}$$

Aber: Erste 2 Gleichungen leben im Datenraum, letzte im Modellraum (Einheiten, Rauschen etc.)

# Regularisierung

Wie können wir die Inversion regulär machen?

Zusätzliche Gleichungen im Modellraum

- A-priori-Wissen über eine Unbekannte (Modellreduktion)
- Beziehung zwischen mehreren Unbekannten (z.B. Summe zweier Mächtigkeiten, Differenz/Glattheit)
- ungefähre Schätzung (Referenzmodell)

Zusammen mit Daten im Sinne kleinster Quadrate zu lösen:

$$\begin{bmatrix} 1 & 1 & 0 \\ 0 & 0 & 1 \\ 1 & -1 & 0 \end{bmatrix}$$

Aber: Erste 2 Gleichungen leben im Datenraum, letzte im Modellraum (Einheiten, Rauschen etc.)

## Regularisierung (2)

Minimierung einer gewichteten Summe (Residuum + Constraints):

$$\|\mathbf{G}\mathbf{m} - \mathbf{d}\|^2 + \lambda^2 \|\mathbf{W}\mathbf{m}\|^2 \rightarrow \min$$

$\lambda$  ist ein Wichtungsfaktor mit Einheit  $[\lambda] = [\text{Daten}]/[\text{Modell}]$ , führt zu

$$(\mathbf{G}^T \mathbf{G} + \lambda^2 \mathbf{W}^T \mathbf{W}) \mathbf{m} = \mathbf{G}^T \mathbf{d}$$

Ist identisch zum inversen Problem

$$\begin{bmatrix} \mathbf{G} \\ \lambda \mathbf{W} \end{bmatrix} \mathbf{m} - \begin{bmatrix} \mathbf{d} \\ 0 \end{bmatrix} \rightarrow \min$$

## Regularisierung (2)

Minimierung einer gewichteten Summe (Residuum + Constraints):

$$\|\mathbf{G}\mathbf{m} - \mathbf{d}\|^2 + \lambda^2 \|\mathbf{W}\mathbf{m}\|^2 \rightarrow \min$$

$\lambda$  ist ein Wichtungsfaktor mit Einheit  $[\lambda] = [\text{Daten}]/[\text{Modell}]$ , führt zu

$$(\mathbf{G}^T \mathbf{G} + \lambda^2 \mathbf{W}^T \mathbf{W}) \mathbf{m} = \mathbf{G}^T \mathbf{d}$$

- Einfachster Fall:  $\mathbf{W}$  ist Einheitsmatrix  $\mathbf{I}$ :  
gedämpfte Normalengleichungen  $\Rightarrow$  kleinstes Modell
- Weiterer häufiger Fall:  $\mathbf{W}$  ist diskrete Ableitungsmatrix:  
smoothness constraints  $\Rightarrow$  glattestes Modell:

# Glattheits-Nebenbedingungen (Smoothness Constraints)

Wir minimieren die Rauigkeit, d.h. Gradienten oder Krümmung im Modell.

Beispiel Rauigkeitsoperator 1. Ableitung für 1D-Modell

$$\begin{bmatrix} -1 & 1 & 0 & \dots & \\ 0 & -1 & 1 & 0 & \dots \\ & \vdots & \ddots & \ddots & \vdots \\ & \dots & 0 & -1 & 1 \end{bmatrix}$$

Beispiel Rauigkeitsoperator 2. Ableitung für 1D-Modell

$$\begin{bmatrix} -1 & 2 & -1 & 0 & \dots & \\ 0 & -1 & 2 & -1 & 0 & \dots \\ \vdots & \vdots & \ddots & \ddots & \ddots & \vdots \\ \dots & \dots & 0 & -1 & 2 & -1 \end{bmatrix}$$

# Glattheits-Nebenbedingungen (Smoothness Constraints)


Wir minimieren die Rauigkeit, d.h. Gradienten oder Krümmung im Modell.

Beispiel Rauigkeitsoperator 1. Ableitung für 2D-Modell

$$\begin{bmatrix} -1 & 1 & 0 & \dots & \dots \\ 0 & -1 & 1 & 0 & \dots \\ \vdots & \vdots & \ddots & \ddots & \vdots \\ \dots & \dots & 0 & -1 & 1 \\ -1 & 0 & \dots & 1 & 0 \\ \vdots & -1 & \dots & 0 & 1 \end{bmatrix} = \begin{bmatrix} \mathbf{W}_x \\ \mathbf{W}_y \end{bmatrix}$$


Alternativ:  $\|\mathbf{Gm} - \mathbf{d}\|^2 + \lambda_x \|\mathbf{W}_x \mathbf{m}\| + \lambda_y \|\mathbf{W}_y \mathbf{m}\| \rightarrow \min$

# Wahl des Regularisierungsparameters $\lambda$



Kompromiss zwischen Datenanpassung und Modellnorm

# Wahl des Regularisierungsparameters $\lambda$





# Wahl des Regularisierungsparameters $\lambda$

## Das Diskrepanzprinzip

Wähle  $\lambda$  so, dass die Daten im Rahmen ihrer Fehler angepasst werden ( $\chi^2 = 1$ ):

$$\min \|\mathbf{Wm}\|_2^2 \quad \text{subject to} \quad \|\hat{\mathbf{Gm}} - \hat{\mathbf{d}}\|_2^2 = N$$

# Auflösung für regularisierte Inversion

generalisierte Inverse:

$$\mathbf{G}^\dagger = (\mathbf{G}^T \mathbf{G} + \lambda^2 \mathbf{W}^T \mathbf{W})^{-1} \mathbf{G}^T$$

Modell-Auflösung:

$$\mathbf{R}^M = \mathbf{G}^\dagger \mathbf{G} = (\mathbf{G}^T \mathbf{G} + \lambda^2 \mathbf{W}^T \mathbf{W})^{-1} \mathbf{G}^T \mathbf{G}$$

nähert sich Einheitsmatrix  $\mathbf{I}$  für  $\lambda \rightarrow 0$

Daten-Auflösung:

$$\mathbf{R}^D = \mathbf{G} \mathbf{G}^\dagger = \mathbf{G} (\mathbf{G}^T \mathbf{G} + \lambda^2 \mathbf{W}^T \mathbf{W})^{-1} \mathbf{G}^T$$

# Referenzmodell-Inversion

Oft macht kleinstes Modell wenig Sinn.

Dann invertiert man oft Modelländerungen  $\Delta \mathbf{m} = \mathbf{m} - \mathbf{m}^R$

$$\mathbf{G}\Delta \mathbf{m} = \Delta \mathbf{d} = \mathbf{d} - \mathbf{G}\mathbf{m}^R$$

und verwendet die gedämpften Normalengleichungen (Abstand zu Referenzmodell wird minimiert)  
Dadurch werden smoothness constraints bewusst vermieden (z.B. bei Timelapse-Inversion sehr kleiner Änderungen)