

Inverse Probleme in der Geophysik
Vorlesung (Vertretung K. Spitzer)
TU Bergakademie Freiberg, SS 2020

Teil 11: Nichtlineare Inversionsprobleme (Fortsetzung 1D-Geoelektrik)

Thomas Günther (LIAG Hannover)
(Thomas.Guenther@extern.tu-freiberg.de)

6. Juli 2020

Heutige Veranstaltung

Fortsetzung 1D-Geoelektrik (JNB live und üben)

- Sensitivitäten für inhomogene Modelle
- Äquivalenzen für leitfähige und resistive Schichten
- Occam-Inversion (korrigiert) mit logarithmischen Parametern
- Block-Inversion mit logarithmischen Parametern
- spielen und ausprobieren

Spezialthema

Fehlermodelle in der Geophysik

Nichtlineare Inversionsprobleme

Iterative Lösung nichtlinearer inverser Probleme

ausgehend von einem Start-Modell \mathbf{m}^0 errechnet man iterativ ($n=0,1,2,\dots$) immer neue Modelle

$$\mathbf{m}^{n+1} = \mathbf{m}^n + \Delta\mathbf{m}^n$$

durch Lösung des linearen Inversionsproblems

$$\mathbf{S}^n \Delta\mathbf{m}^n = \Delta\mathbf{d}^n = \mathbf{d} - \mathbf{f}(\mathbf{m}^n)$$

Alle weiteren Einflüsse (z.B. Regularisierung) können auf $\Delta\mathbf{m}$ angewandt werden.

Nichtlineare Inversionsprobleme

Iterative Lösung nichtlinearer inverser Probleme

ausgehend von einem Start-Modell \mathbf{m}^0 errechnet man iterativ ($n=0,1,2,\dots$) immer neue Modelle

$$\mathbf{m}^{n+1} = \mathbf{m}^n + \tau^n \Delta \mathbf{m}^n$$

durch Lösung des linearen Inversionsproblems


$$\mathbf{S}^n \Delta \mathbf{m}^n = \Delta \mathbf{d}^n = \mathbf{d} - \mathbf{f}(\mathbf{m}^n)$$

Alle weiteren Einflüsse (z.B. Regularisierung) können auf $\Delta \mathbf{m}$ angewandt werden. Der Parameter τ wird auch als Schrittweite bezeichnet und kann optimiert werden, je nachdem wie weit die Taylor-Approximation gilt. Dieser Prozess wird als line search bezeichnet.

Die Zielfunktion und ihre Topologie

Linear

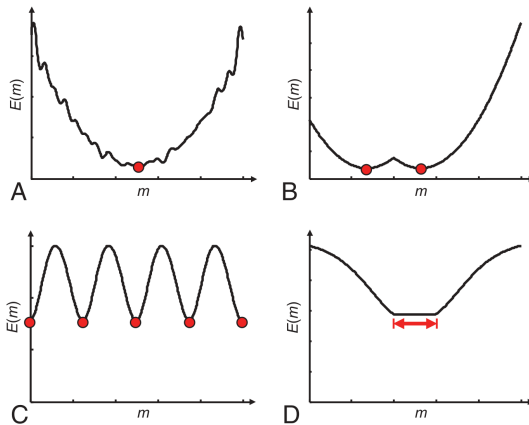
$$\mathbf{d} = \mathbf{G}\mathbf{m}$$




$$\Phi(m) = E(m) = \sum_i (d_i - f_i(m))^2$$

Non-linear

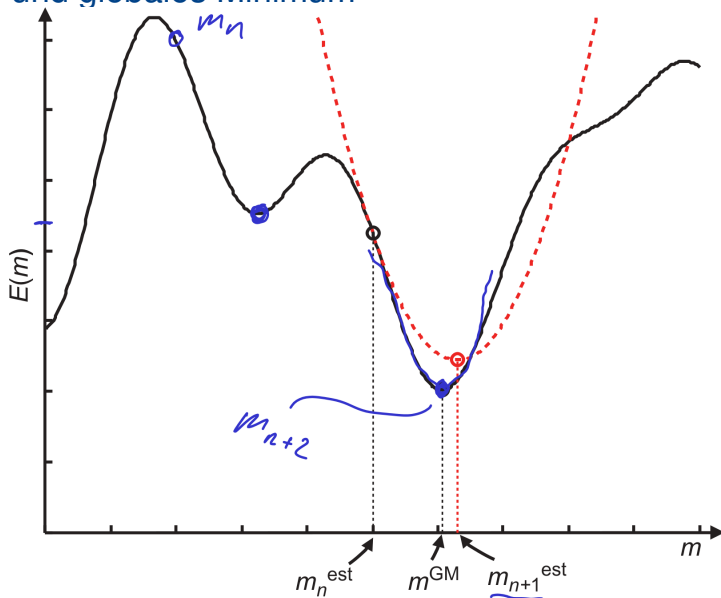
$$\mathbf{d} = \mathbf{G}(\mathbf{m})$$



Linearisierung und lokale Minima



Linearisierung und globales Minimum



Berechnung der Sensitivitätsmatrix

Methoden

- analytische Berechnung (Ableitung von f)
- Lösung einer partiellen Differentialgleichung
- Perturbationsmethode (brute force)

$$\frac{\partial \mathbf{f}(\mathbf{m})}{\partial m_j} \approx \frac{\mathbf{f}(\mathbf{m} + \delta_j \Delta m) - \mathbf{f}(\mathbf{m})}{\Delta m}$$

(jeden Modellparameter verändern und neue Zeile errechnen)

Modelltransformationen

Sei $\mathbf{d} = \mathbf{G}\mathbf{m} + \mathbf{n}$ (z.B. Slowness)

Nehmen wir an, wir invertieren eine andere Größe $\hat{m}(m)$, z.B. Geschwindigkeit $v = 1/s$ anstatt Slowness. Dann ist das Problem nicht mehr linear.

Die Frechet-Ableitungen berechnen sich mit:

$$\frac{\partial f_i(\mathbf{m})}{\partial \hat{m}_j} = \frac{\partial f_i(\mathbf{m})}{\partial m_j} \frac{\partial m_j}{\partial \hat{m}_j}$$

Mit $\hat{m} = v = 1/s$ ergibt sich $\partial s / \partial v = -1/v^2 = -s^2$

Jacobi-Matrix des transformierten Problems

$$\hat{S}_{ij} = \frac{\partial f_i(\mathbf{m})}{\partial \hat{m}_j} = \frac{\partial f_i(\mathbf{m})}{\partial \mathbf{m}_j} \frac{\partial m}{\partial \hat{m}} = \frac{\partial f_i(\mathbf{m})}{\partial \mathbf{m}_j} / \frac{\partial \hat{m}}{\partial m}$$

Methode des steilsten Gradienten

Die Zielfunktion im Sinne kleinster Quadrate ist

$$\Phi(\mathbf{m}) = (\mathbf{d} - \mathbf{f}(\mathbf{m}))^T (\mathbf{d} - \mathbf{f}(\mathbf{m}))$$

Der negative Gradient

$$g(\mathbf{m}) = -\nabla_m \Phi = -\nabla_m (\mathbf{d} - \mathbf{f}(\mathbf{m}))^T (\mathbf{d} - \mathbf{f}(\mathbf{m})) = 2\mathbf{S}^T (\mathbf{d} - \mathbf{f}(\mathbf{m}))$$

gibt die Richtung an, in welche die Zielfunktion abnimmt.

Das entspricht der rechten Seite in den Normalgleichungen für $\Delta\mathbf{m}/\Delta\mathbf{d}$.

Newton-Methode

Taylor-Entwicklung 2. Ordnung der Zielfunktion $\Phi(\mathbf{m}) = (\mathbf{d} - \mathbf{f}(\mathbf{m}))^T (\mathbf{d} - \mathbf{f}(\mathbf{m}))$

$$\Phi(\mathbf{m} + \Delta\mathbf{m}) = \Phi(\mathbf{m}) + (\nabla\Phi)^T \Delta\mathbf{m} + \frac{1}{2} \Delta\mathbf{m}^T (\nabla^2\Phi)^T \Delta\mathbf{m}$$

mit der Hesse-Matrix:

$$(\nabla^2\Phi)_{ij} = \frac{\partial^2\Phi}{\partial m_i \partial m_j}$$

Null-Setzen der ersten Ableitung ergibt:

$$\nabla^2\Phi \Delta\mathbf{m} = -2\nabla\Phi$$

Aber: Die Hesse-Matrix ist meist schwer zu berechnen

$$\nabla\nabla^T\Phi = \nabla(2\mathbf{S}^T(\mathbf{f}(\mathbf{m}) - \mathbf{d})) = 2\mathbf{S}^T\mathbf{S} + 2(\nabla^T\mathbf{S}^T)(\mathbf{f}(\mathbf{m}) - \mathbf{d})$$

Gauss-Newton-Methode

Näherung der Hesse-Matrix mit

$$\nabla \nabla^T \Phi \approx 2 \mathbf{S}^T \mathbf{S}$$

und Vernachlässigung höherwertiger Ableitungen führt zu

$$\mathbf{S}^T \mathbf{S} \Delta \mathbf{m} = \mathbf{S}^T (\mathbf{d} - \mathbf{f}(\mathbf{m})) = \mathbf{S}^T \Delta \mathbf{d}$$

also der Least-Squares-Lösung des linearisierten Problems

Regularisierung von \mathbf{m} (global)

erweiterte Zielfunktion

$$\Phi(\mathbf{m}) = (\mathbf{d} - \mathbf{f}(\mathbf{m}))^T (\mathbf{d} - \mathbf{f}(\mathbf{m})) + \lambda^2 (\mathbf{C}\mathbf{m})^T (\mathbf{C}\mathbf{m})$$

führt zu

$$(\mathbf{S}^T \mathbf{S} + \lambda^2 \mathbf{C}^T \mathbf{C}) \Delta \mathbf{m} = \mathbf{S}^T (\mathbf{d} - \mathbf{f}(\mathbf{m})) - \lambda^2 \mathbf{C}^T \mathbf{C} \mathbf{m}$$

Modelltransformationen

Logarithmische Parameter

Geschwindigkeit oder Slowness? Spez. Widerstand oder Leitfähigkeit?

Oft invertiert man Logarithmen, da so gesichert ist, dass die Parameter positiv bleiben:

Mit $\hat{m} = \log s$ ergibt sich $\partial s / \partial \log s = 1 / (\partial \log s / \partial s) = s$, also eine Skalierung von **S** mit s

Update: $\log m^{n+1} = \log m^n + \Delta m \Rightarrow m^{n+1} = m^n \cdot e^{\Delta m}$

Parametergrenzen

Die Wahl des Logarithmus bietet eine natürliche untere Grenze 0 für das Modell, daher ist es so beliebt (physikalische Plausibilität)

Eine alternative untere Grenze kann gewählt werden mit $\hat{m} = \log(m - m_L)$

Eine obere Grenze kann gewählt werden mit $\hat{m} = \log(m_U - m)$, oder eine Kombination aus beiden:

$$\hat{m} = \log(m - m_L) - \log(m_U - m) = \log \frac{m - m_L}{m_U - m}$$