

# Inverse Probleme in der Geophysik

## Vorlesung (Vertretung K. Spitzer), TU Bergakademie Freiberg, SS 2020

Thomas Günther (LIAG Hannover)  
([Thomas.Guenther@extern.tu-freiberg.de](mailto:Thomas.Guenther@extern.tu-freiberg.de))

19. April 2020

# Inhalt

- 1 Veranstaltung 1: 26.05.
- 2 Veranstaltung 2: 02.06.
- 3 Veranstaltung 3: 23.06.
- 4 Veranstaltung 4: 30.06.
- 5 Veranstaltung 5: 07.07.
- 6 Veranstaltung 6: 14.07.
- 7 Beleg als prüfungsrelevante Leistung

# Heutige Veranstaltung

- kurze Vorstellungsrunde
- Organisatorisches
- Einführung und Motivation
- Auffrischung/Überblick Matlab
- Lineare Inversion, überbestimmte Probleme  
Ein einfachstes Problem gemeinsam und selbst  
Lineare Regression selbst gemacht
- Auflösungsanalyse
- Lineare Inversion, unterbestimmt/gemischt

# Kurze Vorstellung

## Thomas Günther

- Studium der Geophysik, TU Bergakademie Freiberg
- Promotion 2004
- Mathematik in Industrie & Technik, TU Chemnitz
- 2005: GGA Hannover (später LIAG)
- Anwendung: Hydrogeophysik
- numerische Modellierung & Inversion, Geoelektrik/IP, EM, Magnetresonanz, Ra, GPR

## LIAG Hannover

- Leibniz-Institut für Angewandte Geophysik
- finanziert v. Bund & Ländern
- im Geozentrum Hannover (mit BGR, LBEG)
- 110 Beschäftigte (WM+TM)
- methodisch & thematisch orientierte Forschung
- 5 Sektionen (Geoelektrik/EM), und 3 Schwerpunkte (z.B. Grundwasser)

# Korrekt gestellte Probleme

## Korrekt gestelltes Problem

Definition nach Hadamard:

- 1 Es existiert eine Lösung.
- 2 Sie ist eindeutig.
- 3 Die Lösung hängt stabil von den Eingangsdaten ab, d.h. kleine Variationen führen zu kleinen Änderungen.

## Schlecht gestellte Probleme

- 1 Kein Modell kann die Daten perfekt anpassen.
- 2 Innerhalb eines Fehlers können viele Modelle die Daten fitten.
- 3 Kleine Änderungen in den Daten führen zu großen Modelländerungen.

## Angewandte Geophysik

### Messung und Rückschluss auf Struktur & Parameter des Untergrunds

- direkte Verwendung sehr selten (Punktmessungen): Bohrlochgeophysik, flache Magnetik, Bodensensoren, Eigenpotential
- ansonsten: Messung =  $\sum$  Effekte des Untergrundes + Fehler
- Modellbildung (Vereinfachung) und Rekonstruktion

Meist verwendet man fertige Programme zur Auswertung, die man oft nicht durchschaut.

# Ziel der Veranstaltung

nicht:

Programmier-Anleitung für Geophysiker

sondern:

Verständnis für Anwender von Geophysik

- Prozesse verstehen und kontrollieren
- zielgerichtete Wahl von Optionen in Programmen
- Grundlage für Interpretation von Ergebnissen
- Abschätzung von Vertrauensmaßen
- Planung geophysikalischer Experimente

- Auffrischung Matlab
- Übersicht über Probleme und Verfahren
- Einführung mit Mini-Problemen (z.B. lineare Regression)
- Lineare Inversion (Laufzeit-Tomographie)
- Nichtlineare Inversion (Geelektrik)
- Auflösungs- und Fehleranalyse
- kleiner Kurs 2D-Geelektrik-Inversion mit DC2dInvRes als Ergänzung zur Vorlesung  
Geelektrik/EM und Wiederholung
- Einblick in problemangepasste Lösungen aus der Praxis



- von Prof. Korn: Gubbins, D. (2004): Time Series Analysis and Inverse Theory for Geophysicists
- Menke, W. (1989). Geophysical Data Analysis: Discrete Inverse Theory, volume 45 of International Geophysics Series. Academic Press Inc. - Das Standardwerk schlechthin
- Scales & Smith: Introductory geophysical inverse theory (GP605), Samizdat Press, Colorado School of Mines, Golden(CO) (gut verständliche, sprachlich geniale Einführung)
- Friedrich, W.: Inversion geophysikalischer Daten, Vorlesungsskript Universität Stuttgart (gute Beispiele aus der Geophysik)
- Inversion tutorials of the geophysical inversion facility, University of British Columbia, Vancouver - gute Tutorials mit vielen interessanten Beispielen

- MatLab = Matrix Laboratory
- Metasprache zum (numerischen) wissenschaftlichen Rechnen
- Reduzierung auf mathematisch notwendiges Level
- System von Toolboxen (frei, käuflich)
- Fülle von Visualisierungs-Funktionen(2D,3D)
- (einfaches) System zum Erstellen von GUIs
- Compiler zur Erstellung von lauffähigen Programmen
- Anwender: Mathematiker, Ingenieure, Mediziner, ... Geowissenschaftler

- Vektorisierung (Vermeidung von Indizierungsarbeit)

Schleifen

Vektorisiert

```
for i = 1:10,
```

```
    for j = 2:8,
```

```
        A(i,j) = B(i,j+1);    A(1:10,2:8) = B(1:10,3:9);
```

```
    end
```

```
end
```

- Modularisierung (Vermeidung von Mehrfacharbeiten)
- Reduzierung auf mathematisch notwendiges Level
- Abgeschlossene Funktionen und Toolboxen

# Matrizen und Vektoren

```
>> a = [ 1 2 3 ]
```

```
a =
```

```
    1 2 3
```

```
>> b = [ 0;2;1 ]
```

```
    0
```

```
b = 2
```

```
    1
```

```
>> b'
```

```
b =
```

```
    0 2 1
```

```
>> a - b'
```

```
ans =
```

```
    1 0 2
```

# Matrizen und Vektoren

```
>> c = a * b;  \% = Skalarprodukt
```

```
c =  
    7
```

```
>> d = b * a;
```

```
d =  
    0  0  0  
    2  4  6  
    1  2  3
```

```
>> A= [ 1 2 3; 4 5 6; 0 2 0 ];
```

```
A =  
    1  2  3  
    4  5  6  
    0  2  0
```

```
>> x = A*b  
    7
```

```
x = 16
```

# Matrizen und Vektoren

```
>> A\x    \% Gleichungslöser
```

```
0
```

```
ans = 2
```

```
1
```

```
>> x+b    \% Addition
```

```
7
```

```
ans = 15
```

```
5
```

```
>> x.*b    \% elementweise Multiplikation
```

```
0
```

```
ans = 32
```

```
4
```

# Matlab Indizierung

```
>> a = 1:10
```

```
a =
```

```
1 2 3 4 5 6 7 8 9 10
```

```
>> b=0:2:20
```

```
b =
```

```
0 2 4 6 8 10 12 14 16 18 20
```

```
>> b(3)
```

```
ans =
```

```
4
```

```
>> b(4:8)
```

```
ans =
```

```
6 8 10 12 14
```

```
>> b(a)
```

```
ans =
```

```
0 2 4 6 8 10 12 14 16 18
```

# Matlab Indizierung

```
>> b(8:end)
```

```
ans =
```

```
14 16 18 20
```

```
>> b(6:2:end-1)
```

```
ans =
```

```
10 14 18
```

```
>> B=A+1
```

```
B =
```

```
2 3 4
```

```
5 6 7
```

```
1 3 1
```

```
>> B(2,3)
```

```
ans =
```

```
7
```



# Matlab Indizierung

```
>> B(2:3,1:2)
```

```
ans =
```

```
5 6
```

```
1 3
```

```
>> B(3,:)
```

```
ans =
```

```
1 3 1
```

```
>> B(:,2)
```

```
ans =
```

```
3
```

```
6
```

```
3
```

```
>> B(:)
```

```
ans =
```

```
2
```

```
5
```

# Befehle für Vektoren

<code>size(a)</code>	% Größe einer Matrix als Vektor
<code>length(a)</code>	% Länge eines Vektors
<code>max(a), min(a)</code>	% Maximum/Minimum
<code>find(a==1)</code>	% Finden von Elementen
<code>A(A==1)=-1;</code>	% Ersetzen aller 1 durch -1
<code>sort(a)</code>	% Sortieren
<code>diff(a)</code>	% Differenzvektor (1 kürzer)
<code>[ a b c ]</code>	% nebeneinander
<code>[ a;b;c ]</code>	% untereinander
<code>zeros(m,n)</code>	% erzeugt m.n Vektor aus Nullen
<code>ones(m,n)</code>	% erzeugt m.n Vektor aus Einsen
<code>A(:)</code>	% alle Elemente als Spaltenvektor

# Matlab Steuerstrukturen

```
>> if a == 5
```

```
    ...
```

```
else
```

```
    ...
```

```
end
```

```
>> for i = 1:10
```

```
    ...
```

```
end
```

```
>> while(k < kmax)
```

```
    ...
```

```
end
```

## Plotten von Kurven

```
plot(x,y); \% 2D-Kurve  
plot(x,y,'r+:'); \% rot gestrichelt mit +  
plot(x,y1,x,y2); \% Mehrere Kurven  
xlabel, ylabel, title \% Beschriftung  
semilogx, semilogy, loglog \% logarithmisch
```

## Plotten von Flächen (Matritzen)

```
imagesc(x,y,Z); \% x,y..Vektoren, Z..Matrix  
contour \%  
surf, colorbar, ...
```

# Daten und Modell

## Daten

Einzelwerte in Vektor  $\mathbf{d} = [d_1, d_2, \dots, d_N]$

## Modell

Verteilung eines (oder mehrerer) Parameter  $p(x, y, z)$

oft diskretisiert:  $p_{ijk} \Rightarrow \mathbf{m} = [m_1, m_2, \dots, m_M]$

allgemeiner:  $p = \sum m_i p_i(x, y, z)$  mit Basisfunktionen  $p_i$

oder: Strukturparameter (vorgegeben oder flexibel),

z.B. 3-Schichtmodell:  $\mathbf{m} = [p_1, p_2, p_3, h_1, h_2]$

## Schritt 1: Modellbildung

## Occams Prinzip

Das einfachste Modell, welches die Daten (im Rahmen der Fehler) erklären kann, ist vorzuziehen

# Inverses Problem

Bestimme ein Modell **m**, das die Daten **d** im Rahmen des Fehlers erklärt:

$$\mathbf{d} = \mathbf{f}(\mathbf{m}) + \mathbf{n}$$

Vorwärtsantwort (ideale Messung) **f**, Noise **n**

## Lineares Problem

**f** kann als Matrix-Vektorgleichung geschrieben werden

$$\mathbf{d} = \mathbf{Gm} + \mathbf{n}$$

Gravimetrie, Magnetik, MRS, VSP, Tomographie mit geraden Strahlen

# Wie lösen wir das inverse Problem?

## Vorwärtsmodellierung

- gezielt ausprobieren
- alles absuchen (grid search)
- intelligent suchen (Genetische Algorithmen etc.)

## Matrix-basierte Minimierung

- strahlenbasierte Rekonstruktion (ART, SIRT)
- Gradientenverfahren (steepest descent)
- Newton-Verfahren (Gauss-Newton)
- Mischung von Verfahren, Filterung, Dekonvolution

# Warum nicht einfach $\mathbf{m} = \mathbf{G} \backslash \mathbf{d}$ ?

- ❶  $\mathbf{G}$  nicht explizit bekannt (DC-Modellierung)
- ❷  $\mathbf{G}$  nicht invertierbar, meist nicht einmal quadratisch
- ❸ inverse Aufgabe ist nicht korrekt gestellt
  - ❶ Existenz einer Lösung
  - ❷ Eindeutigkeit der Lösung
  - ❸ Stetigkeit bzgl. Daten (Fehlerverhalten)



# Verschiedene Aufgabentypen

Anzahl unabhängiger Messungen  $N$ , Anzahl Modellparameter  $M$

- $N > M$ : überbestimmtes Problem  $\Rightarrow$  Ausgleichsrechnung, Lösung im Sinne kleinster Quadrate
- $N < M$ : Unterbestimmtes Problem  $\Rightarrow$  Zusätzliche Forderungen an Lösung führen zu Eindeutigkeit
- In vielen Fällen: sowohl über- als auch unterbestimmte Parameter gleichzeitig

# Beispiel überbestimmtes Problem

$$m_1 - m_2 = -1$$


(1)

$$2m_1 - m_2 = 0$$

(2)

$$m_1 + m_2 = 2.5$$

(3)



Es gibt mehr unabhängige Gleichungen als Unbekannte.

# Beispiel überbestimmtes Problem

$$m_1 - m_2 = -1$$


(1)

$$2m_1 - m_2 = 0$$

(2)

$$m_1 + m_2 = 2.5$$

(3)



Es gibt mehr unabhängige Gleichungen als Unbekannte.

# Die Methode der kleinsten Quadrate

Ausgangspunkt ist die Minimierung des Residuums  $\|\mathbf{d} - \mathbf{G}\mathbf{m}\|$  Bedingung für ein Extremum ist das Verschwinden der Ableitungen nach allen freien Parametern. Daraus folgen die Normalgleichungen

$$\mathbf{G}^T(\mathbf{d} - \mathbf{G}\mathbf{m}) = 0 = \mathbf{G}^T\mathbf{G}\mathbf{m} - \mathbf{G}^T\mathbf{d}$$

mit der (nun eindeutigen) Least Squares Lösung

$$\mathbf{m} = (\mathbf{G}^T\mathbf{G})^{-1}\mathbf{G}^T\mathbf{d}$$

Maß für die Anpassung ist die (normalisierte) Residuumsnorm

$$\|\mathbf{d} - \mathbf{f}(\mathbf{m})\| = \sqrt{1/N \sum (d_i - f_i(\mathbf{m}))^2}$$

auch bezeichnet als RMS (root mean square)

# Gewichtete Minimierung

## Was passiert bei verschiedener Genauigkeit der Daten?

Wichtung des Datenmisfits durch individuellen Datenfehler  $\varepsilon_i$ :

$$\sum \left( \frac{d_i - f_i(\mathbf{m})}{\varepsilon_i} \right)^2 \rightarrow \min$$

(Ersetzung  $d_i$  durch  $\hat{d}_i = d_i/\varepsilon_i$ ) führt zu

$$\mathbf{m} = (\hat{\mathbf{G}}^T \hat{\mathbf{G}})^{-1} \hat{\mathbf{G}}^T \hat{\mathbf{d}}$$

mit  $\hat{\mathbf{G}} = \text{diag}(1/\varepsilon_i) \cdot \mathbf{G}$


zugehöriges Fehlermaß: fehlergewichteter Misfit (ideal 1)

$$\chi^2 = \frac{1}{N} \sum \left( \frac{d_i - f_i(\mathbf{m})}{\varepsilon_i} \right)^2$$

# Aufgaben Ausgleichsrechnung

- Bestimmen Sie die Lösung mit der Ausgleichsmethode und das RMS-Fehlermaß.
- Verwenden Sie alternativ die gewichtete Methode mit konstanten Fehlern und geben Sie das  $\chi^2$ -Fehlermaß an.
- Wie verändert sich die Lösung, wenn Sie das Fehlermodell variieren?
- Variieren Sie die rechten Seiten (Verschiebung der Geraden) oder Koeffizienten.

# Linear Regression(1)



## Lineare Regression(2)

Die Daten:  $y_i$  Das Modell:  $a, b$  Der Vorwärtsoperator: Abbildung von  $(a, b)$  auf  $a + bx$  durch Matrix-Vektor-Produkt.

- 1 Wie muss diese aussehen? (Überlegung 1, danach 2 Werte)
- 2 Stellen Sie  $\mathbf{G}$  auf und lösen Sie die Normalengleichungen

$$\mathbf{G}^T(\mathbf{d} - \mathbf{G}\mathbf{m}) = 0 \text{ bzw. } \mathbf{G}^T\mathbf{G}\mathbf{m} = \mathbf{G}^T\mathbf{d}$$

- 3 Testen Sie mit idealen Daten (graphischer Vergleich)!
- 4 Verrauschen Sie die Daten und variieren Sie die Fehler.
- 5 Berechnen Sie die Fehlerquadratsumme!
- 6 Wiederholen Sie (neue Verrauschung) & plotten Sie die alle Ergebnisse zusammen! Wie verteilen sie sich?
- 7 Erhöhen Sie den Polynomgrad schrittweise!



# Heutige Veranstaltung 02.06.

- Wiederholung des Stoffes von letzter Woche  
(Motivation, Matlab, einfache lineare & überbestimmte Probleme)
- Auflösungsanalyse
- überbestimmte  $\Rightarrow$  unterbestimmte Probleme
- Regularisierungsverfahren
- 2D Crosshole Laufzeittomographie (linear)
- Singulärwertzerlegung?
-

# Wiederholung 1. Veranstaltung

- Lineare Probleme: Vorwärtsoperator **Gm**
- Daten: Modellantwort plus Fehler **d = Gm + n**
- Überbestimmte Probleme ( $M > N$ )  $\Rightarrow$  Ausgleichsrechnung  
 $\Rightarrow$  Minimierung des Residuums  $\|\mathbf{d} - \mathbf{Gm}\| \rightarrow \min$
- Least Squares Lösung durch Normalgleichungen:

$$\mathbf{G}^T \mathbf{Gm} = \mathbf{G}^T \mathbf{d}$$

- Matlab denkt mit:  $m = \mathbf{G} \setminus \mathbf{d}$
- Maß für Anpassung: Root Mean Square (RMS)

$$\sqrt{1/N \sum (\mathbf{d} - \mathbf{Gm})_i^2} = \|\mathbf{d} - \mathbf{Gm}\| / \sqrt{N}$$

- 3-Geraden-Problem, Lineare Regression

# Rauschen und Fehler

- Fehler (immer da) werden mit invertiert
- Least-Squares-Inversion = Gauss-Verteilung des Residuums
- Modellvariation durch Wiederholung: Fehleranalyse
- je größer Daten-Fehler desto größer Modell-Variation
- auch abhängig von Gutartigkeit des Problems
- ungleiches Rauschen  $\Rightarrow$  systematische Verzerrung
- Wichtung der Daten mit reziprokem Fehler  
 $\Rightarrow$  gewichtete Normalgleichungen

$$\mathbf{m} = (\hat{\mathbf{G}}^T \hat{\mathbf{G}})^{-1} \hat{\mathbf{G}}^T \hat{\mathbf{d}} \text{ mit } \hat{\mathbf{G}} = \text{diag}(1/\varepsilon_i) \cdot \mathbf{G}$$

- Maß für Anpassung:  $\chi^2$  (fehlergewichtetes Quadratmittel)

$$\mathbf{d} = \mathbf{G}\mathbf{m}^{\text{true}} + \mathbf{n}$$

Matrix-Inversion mit inversem Operator  $\mathbf{G}^\dagger$ :

$$\mathbf{m}^{\text{est}} = \mathbf{G}^\dagger \mathbf{d} = \mathbf{G}^\dagger \mathbf{G} \mathbf{m}^{\text{true}} + \mathbf{G}^\dagger \mathbf{n} = \mathbf{R}^M \mathbf{m}^{\text{true}} + \mathbf{G}^\dagger \mathbf{n}$$

mit der Modell-Auflösungsmatrix  $\mathbf{R}^M = \mathbf{G}^\dagger \mathbf{G}$

⇒ Wie spiegelt sich die Wahrheit ( $\mathbf{m}^{\text{true}}$ ) im Ergebnis ( $\mathbf{m}^{\text{est}}$ ) wider?

Überbestimmte Probleme:  $\mathbf{G}^\dagger = (\mathbf{G}^T \mathbf{G})^{-1} \mathbf{G}^T$

⇒ perfekte Modellauflösung

$$\mathbf{R}^M = (\mathbf{G}^T \mathbf{G})^{-1} \mathbf{G}^T \mathbf{G} = \mathbf{I}$$

# Daten-Auflösung

$$\mathbf{m}^{\text{est}} = \mathbf{G}^\dagger \mathbf{d}^{\text{obs}}$$

Wie werden die Daten durch das Modell erklärt?

$$\mathbf{d}^{\text{est}} = \mathbf{G}\mathbf{m}^{\text{est}} = \mathbf{G}\mathbf{G}^\dagger \mathbf{d}^{\text{obs}} = \mathbf{R}^D \mathbf{d}^{\text{obs}}$$

mit der Daten-Auflösungsmatrix (Informationsdichtematrix):

$$\mathbf{R}^D = \mathbf{G}\mathbf{G}^\dagger$$

Diagonale von  $\mathbf{R}^D$ : Informationsgehalt der einzelnen Daten

Überbestimmte Probleme:

$$\mathbf{G}^\dagger = (\mathbf{G}^T \mathbf{G})^{-1} \mathbf{G}^T \quad \Rightarrow \quad \mathbf{R}^D = \mathbf{G}(\mathbf{G}^T \mathbf{G})^{-1} \mathbf{G}^T$$

## Lineare Regression(2)

Die Daten:  $y_i$  Das Modell:  $a, b$  Der Vorwärtsoperator: Abbildung von  $(a, b)$  auf  $a + bx$  durch Matrix-Vektor-Produkt.

- 1 Wie muss diese aussehen? (Überlegung 1, danach 2 Werte)
- 2 Stellen Sie  $\mathbf{G}$  auf und lösen Sie die Normalengleichungen

$$\mathbf{G}^T(\mathbf{d} - \mathbf{Gm}) = 0 \text{ bzw. } \mathbf{G}^T\mathbf{Gm} = \mathbf{G}^T\mathbf{d}$$

- 3 Testen Sie mit idealen Daten (graphischer Vergleich)!
- 4 Verrauschen Sie die Daten und variieren Sie die Fehler.
- 5 Berechnen Sie die Fehlerquadratsumme!
- 6 Wiederholen Sie (neue Verrauschung) & plotten Sie die alle Ergebnisse zusammen! Wie verteilen sie sich?
- 7 Erhöhen Sie den Polynomgrad schrittweise!

# Daten-Auflösung Überbestimmte Probleme

Berechnen Sie für die beiden Beispiel-Probleme (3 Geraden, Lineare Regression) die Datenauf Lösungsmatrix und stellen Sie diese dar

# Problem mit Unterbestimmung

2 Messungen (z.B. Strahlen), 3 Parameter (Zellen)

$$\mathbf{Gm} = \begin{bmatrix} 1 & 1 & 0 \\ 0 & 0 & 1 \\ 0 & 0 & 1 \end{bmatrix} \cdot \begin{bmatrix} m_1 \\ m_2 \\ m_3 \end{bmatrix} = \begin{bmatrix} d_1 \\ d_2 \\ d_3 \end{bmatrix} = \mathbf{d}$$

Zerlegung in zwei Unterprobleme:

- Parameter 3 ist überbestimmt
- Parameter 1+2 unterbestimmt

Alle Lösungen mit  $m_1 = d_1 - m_2$  sind gleichrichtig

Für eindeutige (reguläre) Lösungen müssen zusätzliche Bedingungen gestellt werden  $\Rightarrow$

Regularisierung



# Problem mit Unterbestimmung

2 Messungen (z.B. Strahlen), 3 Parameter (Zellen)

$$\mathbf{Gm} = \begin{bmatrix} 1 & 1 & 0 \\ 0 & 0 & 1 \\ 0 & 0 & 2 \end{bmatrix} \cdot \begin{bmatrix} m_1 \\ m_2 \\ m_3 \end{bmatrix} = \begin{bmatrix} d_1 \\ d_2 \\ d_3 \end{bmatrix} = \mathbf{d}$$

Zerlegung in zwei Unterprobleme:

- Parameter 3 ist überbestimmt
- Parameter 1+2 unterbestimmt

Alle Lösungen mit  $m_1 = d_1 - m_2$  sind gleichrichtig

Für eindeutige (reguläre) Lösungen müssen zusätzliche Bedingungen gestellt werden  $\Rightarrow$

Regularisierung

# Problem mit Unterbestimmung

2 Messungen (z.B. Strahlen), 3 Parameter (Zellen)

$$\mathbf{Gm} = \begin{bmatrix} 1 & 1 & 0 \\ 0 & 0 & 1 \\ 1 & 1 & 2 \end{bmatrix} \cdot \begin{bmatrix} m_1 \\ m_2 \\ m_3 \end{bmatrix} = \begin{bmatrix} d_1 \\ d_2 \\ d_3 \end{bmatrix} = \mathbf{d}$$

Zerlegung in zwei Unterprobleme:

- Parameter 3 ist überbestimmt
- Parameter 1+2 unterbestimmt

Alle Lösungen mit  $m_1 = d_1 - m_2$  sind gleichrichtig

Für eindeutige (reguläre) Lösungen müssen zusätzliche Bedingungen gestellt werden  $\Rightarrow$

Regularisierung

# Regularisierung

Wie können wir die Inversion regulär machen?

Zusätzliche Gleichungen im Modellraum

- A-priori-Wissen über eine Unbekannte (Modellreduktion)
- Beziehung zwischen mehreren Unbekannten (z.B. Summe zweier Mächtigkeiten, Differenz/Glattheit)
- ungefähre Schätzung (Referenzmodell)

Zusammen mit Daten im Sinne kleinster Quadrate zu lösen:

$$\begin{bmatrix} 1 & 1 & 0 \\ 0 & 0 & 1 \\ 1 & 0 & 0 \end{bmatrix}$$

Aber: Erste zwei Gleichungen leben im Datenraum, letzte im Modellraum (Einheiten, Rauschen etc.)

# Regularisierung

Wie können wir die Inversion regulär machen?

Zusätzliche Gleichungen im Modellraum

- A-priori-Wissen über eine Unbekannte (Modellreduktion)
- Beziehung zwischen mehreren Unbekannten (z.B. Summe zweier Mächtigkeiten, Differenz/Glattheit)
- ungefähre Schätzung (Referenzmodell)

Zusammen mit Daten im Sinne kleinster Quadrate zu lösen:

$$\begin{bmatrix} 1 & 1 & 0 \\ 0 & 0 & 1 \\ 1 & 1 & 0 \end{bmatrix}$$

Aber: Erste zwei Gleichungen leben im Datenraum, letzte im Modellraum (Einheiten, Rauschen etc.)

# Regularisierung

Wie können wir die Inversion regulär machen?

Zusätzliche Gleichungen im Modellraum

- A-priori-Wissen über eine Unbekannte (Modellreduktion)
- Beziehung zwischen mehreren Unbekannten (z.B. Summe zweier Mächtigkeiten, Differenz/Glattheit)
- ungefähre Schätzung (Referenzmodell)

Zusammen mit Daten im Sinne kleinster Quadrate zu lösen:

$$\begin{bmatrix} 1 & 1 & 0 \\ 0 & 0 & 1 \\ 1 & -1 & 0 \end{bmatrix}$$

Aber: Erste zwei Gleichungen leben im Datenraum, letzte im Modellraum (Einheiten, Rauschen etc.)

## Regularisierung (2)

Minimierung einer gewichteten Summe (Residuum + Constraints):

$$\|\mathbf{G}\mathbf{m} - \mathbf{d}\|^2 + \lambda^2 \|\mathbf{W}\mathbf{m}\|^2 \rightarrow \min$$

( $\lambda$ -Wichtungsfaktor mit Einheit [ $\lambda$ ]=[Daten]/[Modell])

führt zu

$$(\mathbf{G}^T \mathbf{G} + \lambda^2 \mathbf{W}^T \mathbf{W}) \mathbf{m} = \mathbf{G}^T \mathbf{d}$$

- Einfachster Fall:  $\mathbf{W}$  ist Einheitsmatrix  $\mathbf{I}$ :  
gedämpfte Normalengleichungen  $\Rightarrow$  kleinstes Modell
- Weiterer häufiger Fall:  $\mathbf{W}$  ist diskrete Ableitungsmatrix:  
smoothness constraints  $\Rightarrow$  glattestes Modell:

# Occams Prinzip

William v. Occam, Schottland 14. Jh.:


*Pluralitas non est ponenda sine neccesitate!*

*(Wähle aus allen möglichen Lösungen die einfachste)*

Doch wie können wir einfach mathematisch definieren?

- wenige Modellzellen (z.B. Schichten)
- große Glattheit
- möglichst geringe Kontraste
- möglichst wenige Kontraste
- Schätzung von Wahrscheinlichkeiten (Bayes)
- Maximum der Entropie/Informationsgehalt

# Wahl des Regularisierungsparameters





# Auflösung für regularisierte Inversion

generalisierte Inverse:

$$\mathbf{G}^\dagger = (\mathbf{G}^T \mathbf{G} + \lambda^2 \mathbf{W}^T \mathbf{W})^{-1} \mathbf{G}^T$$

Modell-Auflösung:

$$\mathbf{R}^M = \mathbf{G}^\dagger \mathbf{G} = (\mathbf{G}^T \mathbf{G} + \lambda^2 \mathbf{W}^T \mathbf{W})^{-1} \mathbf{G}^T \mathbf{G}$$

nähert sich Einheitsmatrix  $\mathbf{I}$  für  $\lambda \rightarrow 0$

Daten-Auflösung:

$$\mathbf{R}^D = \mathbf{G} \mathbf{G}^\dagger = \mathbf{G} (\mathbf{G}^T \mathbf{G} + \lambda^2 \mathbf{W}^T \mathbf{W})^{-1} \mathbf{G}^T$$

# Referenzmodell-Inversion

Oft macht kleinstes Modell wenig Sinn.

Dann invertiert man oft Modelländerungen  $\Delta \mathbf{m} = \mathbf{m} - \mathbf{m}^R$

$$\mathbf{G}\Delta \mathbf{m} = \Delta \mathbf{d} + \mathbf{n} = \mathbf{d} - \mathbf{G}\mathbf{m}^R + \mathbf{n}$$

und verwendet die gedämpften Normalengleichungen (Abstand zu Referenzmodell wird minimiert)  
Dadurch werden smoothness constraints bewusst vermieden (z.B. bei Timelapse-Inversion sehr kleiner Änderungen)

# Aufgaben Regularisierung

Wir betrachten das zuvor diskutierte gemischt bestimmte Problem oder eine Variante der letzten Zeile.

- ➊ Versuchen Sie zunächst den backslash  $m=G \backslash d$
- ➋ Lösen Sie formell nach den Normalengleichungen
- ➌ Lösen Sie mit Hilfe der gedämpften Normalengleichung unter Variation des Regularisierungs-Parameters
  - ▶ Plotten Sie  $m_1$  gegen  $m_2$
  - ▶ Plotten Sie Modellnorm gegen Residuumsnorm
- ➍ Wiederholen Sie die letzte Übung mit einer diskreten Ableitungsmatrix
- ➎ Verwenden Sie ein von Null verschiedenes Referenzmodell und wiederholen Sie 3.

# Zusammenfassung 1.+2. Veranstaltung

- Unterscheidung unter-/über-bestimmte Probleme
- überbestimmt: Ausgleichsrechnung (Normalengleichungen)
- Beispiele: 3 Linien, lineare Regression, gemischtes Problem
- unterbestimmt  $\Rightarrow$  Regularisierung (zusätzliche Annahmen):
  - ▶ Constraints (z.B. Summe Mächtigkeiten)
  - ▶ Glattheit (Differenz minimieren)
  - ▶ Parameter (Abweichungen) klein halten
- Regularisierungsparameter: Datenfit vs. Constraints
- Auflösungsanalyse: Verknüpfung Vorwärts+Invers
  - ▶ Modellauflösungsmatrix  $R^M = \mathbf{G}^\dagger \mathbf{G}$   
Auflösung der Parameter (Diagonale) und ihr Zusammenhang
  - ▶ Dateninformationsmatrix  $R^D = \mathbf{G}\mathbf{G}^\dagger$   
Wichtigkeit der Daten (Diagonale) und ihr Zusammenhang
- Anpassungsmaße, Fehlerwichtung, Referenzmodell

# Die heutige Übung

- Zusammenfassungen
- Fertigstellung Aufgaben Regularisierung (gemischtes Problem)
- echt geophysikalisches Problem: 2D-Laufzeit-Tomographie
- Downloaden und Ausprobieren einiger Funktionen
- Erzeugen einer Crosshole-Geometrie und synth. Rechnungen
- Inversion mit verschiedenen Verfahren
- Klassische Strahl-Rekonstruktions-Verfahren

# Lineare Laufzeit-Tomographie

## Prinzip

Gesamt-Laufzeit integriert über Strahlweg  $l$

$$t = \int_{\text{Strahl}} 1/v \, dl = \int_{\text{Strahl}} s \, dl$$

( $t$ -Laufzeit,  $v$ =Geschwindigkeit,  $s$ -Slowness,  $l$ -Weg)

Das Problem ist linear bezüglich  $s$  (nicht  $v$ !)

Diskretisierung (konstante  $v/s$ ): Integral  $\Rightarrow$  Summe  $\sum w_j s_j$

$$t_i = \sum_j W_{ij} s_j \Rightarrow \mathbf{t} = \mathbf{W} \mathbf{s}$$

Wege-Matrix  $\mathbf{W}$ :  $W_{ij}$  = Weglänge des Strahls  $i$  durch die Zelle  $j$

# Amplituden-Tomographie

z.B. Röntgen-Tomographie (CT)

Dämpfung der Amplitude  $A$  durch Dämpfungskonstante  $\mu$

$$A = A_0 e^{-\int \mu dl}$$

Transformation in logarithmische Amplitudenverhältnisse

$$P = \ln \frac{A}{A_0} = - \int_I \mu dl$$

⇒ Amplitudenabnahme linear bezüglich Dämpfung  
(Lösung wie Laufzeit-Tomographie)

# Lineare Laufzeit-Tomographie

## Vorwärtsrechnung

- Downloaden Sie die Funktion `http://resistivity.net/invprob/matlab/wmatrix.m` und schauen sich die Hilfe an (`help wmatrix`)!

`W = wmatrix(x,y,pos,it,ir)`

- Sie berechnet die Weglängen durch die Zellen eines 2D-Gitters (x,y) aufgrund der Transmitter/Receiver-Kombination it/ir mit den Positionen pos (unabhängig von Geschwindigkeit = linear!)
- Erzeugen Sie sich eine Bohrlochgeometrie mit 2 Bohrlöchern (pos), Transmitter in der einen und Receiver in der anderen, sowie eine dazwischen liegende Diskretisierung x/y



# Laufzeit-Tomographie

## Darstellung des Modells

<http://resistivity.net/invprob/matlab/drawfield.m>

```
W = drawfield(x,y,field)
```

```
W = drawfield(x,y,field,pos,it,ir,rays)
```

# Laufzeit-Tomographie

## Darstellung des Modells

```
http://resistivity.net/invprob/matlab/drawfield.m
```

```
W = drawfield(x, y, field)
```

```
W = drawfield(x, y, field, pos, it, ir, rays)
```

Erzeugen Sie ein (zunächst homogenes) Slowness-Modell (Größen von x und y beachten!) und berechnen Sie daraus die Laufzeit! Checken Sie ob Minimum/Maximum stimmen.

Variieren Sie die Slowness in einem bestimmten Bereich und vergleichen Sie das Ergebnis mit dem homogenen Modell (Verhältnis)!

# Laufzeit-Tomographie

## Darstellung der Daten

`http://resistivity.net/invprob/matlab/drawdata.m`

`W = drawdata(it, ir, data)`

plottet eine Funktion als Matrix über `it` und `ir`

Stellen Sie die Laufzeit mit der Funktion `drawdata` dar.

## Das Konzept der scheinbaren Modelle

Jeder Datenpunkt wird in einen Parameter transformiert, dass dieser bei einem homogen Modell die Daten erklärt.

Hier: Laufzeit durch Gesamtweg = scheinbare Slowness

Gesamtweg in Matlab: Summe über alle Modelle (2. Dim.) `sum(W, 2)`

# Laufzeittomographie: Aufgaben

- Erzeugen Sie eine Crosshole-Geometrie (2 Bohrlöcher mit äquidistanten Sensorpositionen) und entsprechende Sender/Empfänger-Kombinationen
- Diskretisieren Sie den Raum zwischen den Bohrlöchern durch x- und y-Vektor
- Berechnen Sie die Wegmatrix mit `wmatrix.m`
- Stellen Sie die Weglängen einzelner Strahlen (Daten/Zeilen) dar und prüfen Sie auf Plausibilität
- Stellen Sie die Überdeckung (Summe aller Weglängen) des Modellgebiets dar. Welche Auflösung ist zu erwarten?
- Berechnen Sie die Laufzeiten für einen homogenen Untergrund.
- Bauen Sie eine Geschwindigkeitsanomalie ein und vergleichen Sie die Laufzeitvektoren

# Zusammenfassung letzte Veranstaltung

- lineare überbestimmte und unterbestimmte Probleme abgehakt
- Regularisierungsverfahren: Dämpfung, Smoothness
- Beispiel Laufzeittomographie (linearer Laufweg)
- 2 Bohrlöcher mit Positionen (pos) und Tx-Rx-Paaren (it,ir)
- Modelldiskretisierung (x,y)
- Modelldarstellung mit `drawfield(x,y,m)`
- Berechnung der Wegmatrix mit `wmatrix(x,y,pos,it,ir)`
- Datendarstellung mit `drawdata(it,ir,d)`

Konkrete Fragen?

# Klassische Rekonstrukstechniken

ART (Algebraische Rekonstrukstechnik):

$$\Delta m_j = \frac{G_{ij} \Delta d_i}{\sum_k G_{ik}^2}$$

(Herleitung Tafel)

SIRT (Simultane Iterative Rekonstruktions-Technik)

$$\Delta m_j = \frac{1}{\sum_i G_{ij}} \sum_j \frac{G_{ij} \Delta d_i}{\sum_k G_{ik}}$$

## Laufzeittomographie: Aufgaben (2)

- Erstellen Sie ein synthetisches Modell und verrauschen Sie dessen Vorwärtsantwort. Stellen Sie Daten als Laufzeiten und scheinbare Slowness dar.
- Bestimmen Sie eine Lösung mit den Verfahren ART und SIRT
- Errechnen Sie eine Lösung mit den gedämpften Normalengleichungen, einmal direkt und einmal mit Startmodell.
- Variieren Sie den Regularisierungsparameter und stellen Sie Datenmisfit und Modellnorm dar. Wie ist  $\lambda$  zu wählen?
- Wiederholen Sie alles mit Ableitungsmatrix 1. Ordnung  
`http://resistivity.net/invprob/matlab/smooth2d1st.m`
- Berechnen Sie Modell- und Datenauflösungsmatrix und stellen Sie jeweils die Diagonalen und ausgewählte Spalten dar!

# Die heutige Übung und darüber hinaus

## Laufzeit-Tomographie

- Vergleich gedämpfte Normalgleichungen und Smoothness
- Vergleich Regularisierung Modell und Modellupdate
- Optimierung des Regularisierungsparameters mittels Fehlern
- Berechnung der Auflösungsmatrizen (Modell,Daten)
- Tests mit verschiedenen Modellen (Form, Kontrast)

## Nichtlineare Inversion

- Grundkonzepte der nichtlinearen Inversion
- Laufzeittomographie mit logarithmischem Modell

## 1D-Geoelektrik-Inversion

- Block-Inversion mit Marquardt-Levenberg-Verfahren
- Smoothness-constrained Inversion, blocky model constraints



# Die heutige Übung & das Ende der Vorlesung

## Zusammenfassung Laufzeit-Tomographie

- Smoothness Constraints mit bester Abbildung abhängig von Form&Kontrast der Anomalie, Fehlern etc.
- Verschmierung der Anomalie, v.a. horizontal

## Nichtlineare Inversion

- Grundkonzepte der nichtlinearen Inversion

## 1D-Geoelektrik-Inversion

- Sensitivitäten
- Block-Inversion mit Marquardt-Levenberg-Verfahren
- Smoothness-constrained Inversion, blocky model constraints

# Nichtlineare Probleme

bisher: Referenzmodell-Inversion (Dämpfung von  $\Delta \mathbf{m}$ )

$$\mathbf{G}\Delta \mathbf{m} = \Delta \mathbf{d} = \mathbf{d} - \mathbf{Gm}$$

Jetzt:  $\mathbf{d} = \mathbf{f}(\mathbf{m}) + \mathbf{n} \Rightarrow$  Minimierung von  $\|\mathbf{f}(\mathbf{m}) - \mathbf{d}\|$

Linearisierung (Taylor-Entwicklung) f. alle Daten

$$f_i(\mathbf{m} + \Delta \mathbf{m}) \approx f_i(\mathbf{m}) + \sum_j \frac{\partial f_i(\mathbf{m})}{\partial m_j} \Delta m_j = d_i \Rightarrow \mathbf{d} - \mathbf{f}(\mathbf{m}) = \mathbf{S}\Delta \mathbf{m}$$

$\mathbf{S}$  - Sensitivitätsmatrix/Jacobimatrix mit  $S_{ij} = \frac{\partial f_i(\mathbf{m})}{\partial m_j}$  abhängig von  $\mathbf{m}$ !

Iterative Lösung ( $k$  Iterationsschritt) wie lineare Inversion

$$\mathbf{m}^{k+1} = \mathbf{m}^k + \Delta \mathbf{m}^k \quad \text{mit} \quad \mathbf{S}\Delta \mathbf{m}^k = \mathbf{d} - \mathbf{f}(\mathbf{m}^k) = \Delta \mathbf{d}^k$$

# Berechnung der Jacobimatrix

- analytisch (selten möglich)
- Umformung des Vorwärtsproblems
- Differentialgleichungsmethoden
- Updatemechanismen (Broyden)
- Perturbationsmethode, d.h. für jede Spalte

$$\mathbf{s}_j = \frac{\mathbf{f}(\mathbf{m} + \Delta\mathbf{m}_j)}{\Delta m_j} \quad \text{mit} \quad \Delta\mathbf{m}_j = [0 \dots 1 \dots 0] \Delta m_j$$

$M$  zusätzliche Vorwärtsrechnungen (Perturbationen)

$\Delta m_j$  nicht zu groß (Linearisierung) oder zu klein (Genauigkeit)

# Line Search

Manchmal (wenn stark nichtlinear) schießt das Modellupdate  $\Delta \mathbf{m}$  über das Ziel hinaus, d.h.

$\mathbf{f}(\mathbf{m} + \Delta \mathbf{m})$  fittet schlechter als  $\mathbf{f}(\mathbf{m})$

⇒ Einführung einer Schrittweite  $s^k \in (0, 1)$ :

$$\mathbf{m}^{k+1} = \mathbf{m}^k + s^k \Delta \mathbf{m}^k$$

Optimierung von  $s^k$  so, dass  $\|\mathbf{d} - \mathbf{f}(\mathbf{m}^k + s^k \Delta \mathbf{m}^k)\| \rightarrow \min$

- Ausprobieren (z.B.  $s=0.3$  nehmen) und Konvergenz ansehen
- Test (Vorwärtsrechnung) für viele  $s \Rightarrow$  teuer!
- lineare Interpolation zwischen  $\mathbf{f}(\mathbf{m}^k)$  und  $\mathbf{f}(\mathbf{m}^k + \Delta \mathbf{m}^k)$
- Rechnung für 2 Schritte  $(0, 0.3, 1) \Rightarrow$  Parabel  $\Rightarrow$  Minimum

# Transformationen

Oft wird nicht der Modellparameter  $m$ , sondern eine Funktion  $\hat{m}$  von ihm verwendet.

Typisches Beispiel:

Verwendung von Logarithmen  $\hat{m} = \log m$ , um  $m$  positiv zu halten. (Elektrische Leitfähigkeit oder spez. Widerstand bevorzugt gute bzw. schlechte Leiter  $\Rightarrow$  Logarithmus)

Veränderung des Jacobimatrix:

$$\hat{S}_{ij} = \frac{\partial f_i(\mathbf{m})}{\partial \hat{m}_j} = \frac{\partial f_i(\mathbf{m})}{\partial m_j} \frac{\partial m}{\partial \hat{m}} = \frac{\partial f_i(\mathbf{m})}{\partial m_j} / \frac{\partial \hat{m}}{\partial m}$$

# Logarithmus-Transformationen

Motivation: positive Parameter, statistische Verteilung , meist relative Fehler

## Innere Ableitung und Jacobimatrix

$$\partial \log m / \partial m = 1/m \Rightarrow \hat{S}_{ij} = S_{ij} * m_j$$

Modellupdate:  $\log m^{k+1} = \log m^k + \Delta m \Rightarrow m^{k+1} = m^k * e^{\Delta m}$

## Transformationen mit Grenzen

untere Grenze:  $\hat{m} = \log(m - m_L)$ , obere Grenze:  $\hat{m} = \log(m_U - m)$

Range-Funktion:  $\hat{m} = \log(m - m_L) - \log(m_U - m)$

## Datentransformation

$$\hat{S}_{ij} = \frac{\partial \hat{f}_i(\mathbf{m})}{\partial \hat{m}_j} = \frac{\partial f_i(\mathbf{m})}{\partial m_j} \frac{\partial \hat{d}}{\partial d} / \frac{\partial \hat{m}}{\partial m}$$

$\hat{d} = \log d$  und  $\hat{m} = \log m$  führt zu  $\hat{S}_{ij} = S_{ij} * d_i / m_j$

## Schlumberger-Tiefensondierung

- Grundlagen siehe Vorlesungen Einführung o. Geoelektrik

## Aufgaben

- Downloaden Sie die Funktion `http://resistivity.net/invprob/matlab/dc1dfwd.m` und schauen sich die Hilfe an (`help dc1dfwd`)!
- Erzeugen Sie eine (logarithmische) Folge von  $AB/2$ -Abständen sowie passende  $MN/2$ -Abstände.
- Generieren Sie einen 2-Schichtfall, berechnen und plotten Sie die synthetische Kurve (loglog).
- Verändern Sie einzelne Modellparameter und sehen Sie sich die Veränderung an.
- Erhöhen Sie die Anzahl Schichten.

# Geoelektrik-Inversion

grundsätzlich zwei Modelltypen:

## Block-Inversion

- Veränderung von Schicht-Mächtigkeiten und spez. Widerständen
- relativ wenige unabhängige Modellparameter
- gedämpfte Normalgleichungen  $\Rightarrow$  Marquart-Levenberg-Verfahren:  
schrittweise Verringerung des Dämpfungsparameters

## Smooth-Inversion (typisch 2D/3D)

- feste Schicht-Mächtigkeiten und spez. Widerständen
- Regularisierung mit Smoothness Constraints
- feste Regularisierungs-Stärke: probieren, Fehler, L-Kurve

Bei beiden: Vektor für spez. Widerstände und Mächtigkeiten



# Sensitivitätsberechnung Smooth

Logarithmen: relative Veränderung der Modellantwort bei relativer Veränderung der Modell um Faktor fak (z.B. 1.05)

```
S = zeros(length(ab2),length(rho));  
R0 = dc1dfwd(rho,thk,ab2,mn2);  
fak = 1.05;  
for i=1:length(rho),  
    rho1 = rho;  
    rho1(i) = rho(i)*fak;  
    R = dc1dfwd(rho1,thk,ab2,mn2);  
    S(:,i) = (log(R(:))-log(R0(:))) / log(fak);  
end
```

<http://resistivity.net/invprob/matlab/dc1dsmoothsens.m>

# Sensitivitätsberechnung Block

Logarithmen: relative Veränderung der Modellantwort bei relativer Veränderung der Modell um Faktor fak (z.B. 1.05)

```
S = zeros(length(ab2),length(rho)+length(thk));  
...  
for i=1:length(rho),  
...  
for i=1:length(thk),  
    thk1=thk;  
    thk1(i)=thk(i)*fak;  
    R=dc1dfwd(rho,thk1,ab2,mn2);  
    S(:,i+length(rho))=(log(R(:))-log(R0(:)))/log(fak);  
end
```

<http://resistivity.net/invprob/matlab/dc1dblocksens.m>

# Aufgaben

- Erzeugen Sie sich einen synthetischen 2-Schicht-Fall und verrauschen Sie dessen Antwort mit Relativfehler  $\Rightarrow \mathbf{d}$
- Erzeugen Sie einen angemessenen Mächtigkeitsvektor (thk)
- Generieren Sie ein homogenes Startmodell ( $\rho$ )
- Berechnen Sie das Residuum  $\Delta \hat{\mathbf{d}} = \hat{\mathbf{d}} - \hat{\mathbf{f}}(\mathbf{m})$
- Berechnung der Sensitivitätsmatrix und Darstellung
- Erzeugen Sie eine Ableitungsmatrix und berechnen Sie das Modellupdate  $\Delta \mathbf{m}$  mittels Smoothness Constraints
- Updaten Sie das Modell und berechnen Sie dessen Antwort sowie den RMS-Fehler
- Schreiben Sie eine Schleife darum und variieren Sie  $\lambda$
- Gleiche Vorgehensweise mit Blockmodell und Verfahren nach Marquardt-Levenberg ( $\lambda = \lambda * 0.8$ )

# Belegaufgaben

## Ziel

Nachweis des Verständnisses der Inversionsverfahren und Methoden (Laufzeittomographie, 1D-Geoelektrik) durch Modifikation/Erstellung von Matlab-Scripten, Darstellung und Interpretation der Ergebnisse

## Inhalt

- kurze Darstellung der Ausgangsposition (Experiment-Geometrie und Modelldiskretisierung, synthetisches Modell, Rauschen)
- Beschreibung des Inversionsansatzes
- Diskussion der Ergebnisse (Modelle und Auflösungsmaße)

## Abgeben (bis Semesterende)

Dokument (pdf) und dokumentierte Scripte per Email an:  
Thomas.Guenther@uni-leipzig.de

# Belegaufgaben Teil 1: Laufzeittomographie

- 1 Erstellen Sie eine Modellgeometrie mit zwei 10 m entfernten Bohrlöchern sowie Geophonen an der Oberfläche.
- 2 Generieren Sie ein realistisches (wenige 100 bis 1000 m/s) Modell mit langsamen & schnellen Anomalien.
- 3 Addieren Sie zu den synthetischen Laufzeiten Gauss-verteiltes, realistisches (0.5-1 ms) Rauschen!
- 4 Invertieren Sie mit Smoothness Constraints und optimieren Sie dabei den Regularisierungsparameter, so dass Daten im Rahmen der Fehler gefittet werden.
- 5 Stellen Sie das Auflösungsmaß dar und vergleichen Sie mit der Gesamt-Überdeckung (kumulierte Weglänge pro Zelle)
- 6 Interpretieren Sie Ergebnis und Auflösung!

## Belegaufgaben Teil 2: 1D-Geoelektrik

- 1 Generieren Sie ein synthetisches 3-Schicht-Modell sowie eine passende Folge von AB/2-Werten und modellieren Sie.
- 2 Addieren Sie auf die Kurve ein relatives Rauschen von 2 %.
- 3 Erstellen Sie ein homogenes Startmodell mit dem mittleren  $\rho_a$ -Wert, berechnen und diskutieren Sie die Jacobimatrix.
- 4 Ändern Sie den mittleren Widerstand leicht und wiederholen Sie.
- 5 Erzeugen Sie den (logarithmischen) Datenmisfit und lösen die gedämpften Normalgleichungen sowie updaten Sie das Modell.
- 6 Wiederholen Sie den letzten Schritt und verringern Sie dabei den Dämpfungsparameter in jeder Iteration um 20%. Geben Sie jeweils den relativen root mean square error an.
- 7 Optimieren Sie das Script bis die Daten im Rahmen der Fehler gefittet werden. Vergleichen Sie mit dem synth. Modell.
- 8 Berechnen Sie die Informationsdichtematrix, stellen Sie diese dar und interpretieren Sie diese.